



UANL

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN



FIME

FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA

Universidad Autónoma de Nuevo León  
Facultad de Ingeniería Mecánica y Eléctrica

Laboratorio de Tópicos Selectos de Ciencias de la  
Ingeniería III

Práctica 5:

K Means Clustering

Maestro: Said Zamora

José Luis Morales Loyola 1948571

Karen Yareth De Jesus Zapata 1955332

Carlos Yair Hernandez Hernandez 1952660

Angel Eduardo Conde Castro 1927526

Grupo: 507 Hora: Viernes N1-N2

Periodo: Agosto – Diciembre 2025

Ciudad universitaria, 23 de noviembre de 2025.

## Objetivo

- Encontrar la cantidad de centros de clasificación adecuada para un registro determinado mediante el método de medias móviles

## Marco Teórico

### Agrupamiento de Datos (Clustering)

El clustering es una técnica de aprendizaje no supervisado que permite dividir un conjunto de datos en grupos homogéneos, llamados clusters, de manera que los elementos dentro de un mismo grupo sean más similares entre sí que con los de otros grupos. Esta técnica es ampliamente utilizada en áreas como minería de datos, análisis de mercado y clasificación social.

### Aplicación

En esta práctica, el agrupamiento se aplica para identificar grupos de países con características socioeconómicas similares, en función de variables como homicidios, pobreza, desempleo, coeficiente de Gini e índice de desarrollo humano (IDH). Esto facilita el análisis de patrones regionales y la toma de decisiones basada en datos.

### Algoritmo K-means

El algoritmo K-means es uno de los métodos de agrupamiento (clustering) más utilizados en el análisis de datos debido a su simplicidad, eficiencia y capacidad de escalar a grandes volúmenes de información. Su objetivo es particionar un conjunto de observaciones en K grupos distintos (clusters), donde cada observación pertenece al grupo con el centroide más cercano. Un centroide representa el centro geométrico del grupo, calculado como el promedio de todas las observaciones asignadas a ese cluster.

El algoritmo sigue un enfoque iterativo que minimiza la suma de las distancias cuadradas entre los puntos y su centroide correspondiente, buscando así formar grupos lo más compactos y homogéneos posibles.

El proceso del algoritmo K-means se puede resumir en los siguientes pasos:

- 1. Inicialización:** Se seleccionan K puntos aleatorios del conjunto de datos como centroides iniciales.
- 2. Asignación de grupos:** Cada observación se asigna al grupo cuyo centroide esté más cerca, generalmente usando la distancia euclidiana.
- 3. Actualización de centroides:** Se recalculan los centroides como el promedio de todas las observaciones asignadas a cada grupo.
- 4. Repetición:** Se repiten los pasos de asignación y actualización hasta que los centroides ya no cambian significativamente o se alcanza un número máximo de iteraciones.

Este procedimiento garantiza una convergencia local, aunque no necesariamente global. Por esta razón, se recomienda ejecutar el algoritmo varias veces con diferentes inicializaciones (por ejemplo, usando el parámetro `nstart` en R) para aumentar la probabilidad de encontrar una mejor solución.

### Parámetro K (Número de Clusters)

El valor de K, que representa la cantidad de clusters deseados, debe definirse antes de ejecutar el algoritmo. Sin embargo, en muchos problemas reales este número no es conocido de antemano. Para abordarlo, existen técnicas como el método del codo (Elbow Method) y la estadística de la brecha (Gap Statistic), que ayudan a determinar el valor óptimo de K observando cómo varía la cohesión dentro de los clusters a medida que aumenta K.

Seleccionar un valor de K demasiado bajo puede producir agrupamientos demasiado generales, mientras que un valor demasiado alto puede generar una segmentación artificial y poco interpretativa.

## **Algoritmo PAM (Partitioning Around Medoids)**

PAM es una variante más robusta del K-means. En lugar de utilizar promedios (centroides), elige puntos reales del conjunto como representantes (medoides). Esto hace que PAM sea más resistente a valores atípicos y apropiado cuando se utilizan otras medidas de distancia distintas a la euclidiana.

## **Medias Móviles y su Rol en el Análisis Exploratorio**

Aunque tradicionalmente las medias móviles son una técnica de análisis de series temporales, también pueden emplearse como herramienta exploratoria o de preprocesamiento antes de aplicar algoritmos de P06 K means clustering  $\equiv$  4 agrupamiento. La media móvil consiste en suavizar una secuencia de datos reemplazando cada valor por el promedio de sus vecinos inmediatos. Esto permite:

- Reducir el ruido de los datos.
- Detectar tendencias generales cuando hay variabilidad local.
- Preparar datos suavizados que revelen estructuras más claras para el análisis de clusters.

En el contexto de esta práctica, el término “medias móviles” puede interpretarse como una etapa previa de preprocesamiento o suavizado, aplicada sobre indicadores como pobreza, desempleo o homicidios, con el fin de facilitar la identificación de agrupaciones estables al aplicar K-means o PAM.

## **Limitaciones**

K-means es sensible a los valores atípicos y a la escala de los datos. Por ello, es recomendable normalizar los datos antes de aplicar el algoritmo.

## Desarrollo

### 1. Importar librerías

- **cluster:** para K-means, PAM y CLARA
- **factoextra:** para visualizar clusters y métodos para elegir K
- **tidyverse:** manipulación de datos

```
> library(cluster)
```

```
> library(factoextra)
```

```
> library(tidyverse)
```

### 2. Importar el archivo LAKE SAMP

Abre una ventana para elegir el archivo CSV (“LAKE SAMP”).

Carga los datos en un data frame llamado datos.

```
> datos <- read.csv(file.choose(), header = TRUE)
```

### 3. Preparar los datos

Esto se hace porque la primera columna suele ser el nombre de la muestra, no una variable numérica.

```
datos <- datos[, -1]      # Elimina la primera columna del dataset
```

### 4. Normalizar los datos

Se estandariza cada variable con media 0 y desviación estándar 1.

Es obligatorio antes de aplicar clustering → para evitar que una variable domine por tener valores grandes.

```
> datos_norm <- scale(datos)
```

## 5. Determinar el número óptimo de clusters

### 5.1 Método Silhouette

Evalúa qué tan bien separado está cada cluster.

```
> fviz_nbclust(datos_norm, kmeans, method = "silhouette") + labs(title = "Número óptimo de clusters (K-means - Silhouette)")
```

### 5.2 Método del Codo (Elbow)

Busca el punto donde dejar de agregar clusters no mejora mucho la compactación.

```
> fviz_nbclust(datos_norm, kmeans, method = "wss") + labs(title = "Número óptimo de clusters (K-means - Elbow)")
```

### 5.3 Gap Statistic

Es el método más robusto. Compara tu estructura real VS datos aleatorios.

```
> gap_stat <- clusGap(datos_norm, FUN = kmeans, nstart = 25, K.max = 10, B = 50)
```

```
> fviz_gap_stat(gap_stat) + labs(title = "Número óptimo de clusters (Gap Statistic)")
```

## 6. Aplicar K-means con K=3

centers = 3 → número de clusters

nstart = 25 → repite 25 veces para evitar malas inicializaciones

```
> km_res <- kmeans(datos_norm, centers = 3, nstart = 25)
```

## 7. Visualizar los clusters K-means

Genera un gráfico con:

- puntos según sus coordenadas normalizadas
- colores según cluster
- elipses que delimitan grupos

```
fviz_cluster(km_res, data = datos_norm,
```

```
  ellipse.type = "convex",
```

```
  palette = "jco",
```

```
  ggtheme = theme_minimal())
```

## 8. Determinar K para PAM

PAM encuentra un representante REAL del cluster (medoide). Es más robusto que K-means.

```
> fviz_nbclust(datos_norm, pam, method = "silhouette") + labs(title = "Número óptimo de  
clusters (PAM)")
```

## 9. Aplicar PAM con K=3

```
> pam_res <- pam(datos_norm, k = 3)
```

## 10. Visualización de PAM

```
fviz_cluster(pam_res, data = datos_norm,
```

```
  ellipse.type = "t",
```

```
  palette = "jco",
```

```
  ggtheme = theme_minimal())
```

## 11. Aplicar CLARA (muestras grandes)

CLARA = PAM pero para bases de datos grandes, trabaja por muestras.

```
> clara_res <- clara(datos_norm, k = 3, samples = 50, pamLike = TRUE)
```

## 12. Visualizar CLARA

```
fviz_cluster(clara_res, data = datos_norm,
```

```
  ellipse.type = "norm",
```

```
  palette = "jco",
```

```
  ggtheme = theme_minimal()) +
```

```
labs(title = "Clustering CLARA")
```

## 13. Combinar los resultados

Ahora cada fila tiene **3 columnas nuevas** con la clasificación asignada por cada método.

```
datos_clasificados <- datos %>%
```

```
  mutate(Cluster_KMeans = km_res$cluster,
```

```
    Cluster_PAM = pam_res$clustering,
```

```
    Cluster_CLARA = clara_res$clustering)
```

## 14. Ver los primeros resultados

```
head(datos_clasificados)
```


## 15. Exportar archivo final

```
write.csv(datos_clasificados, "datos_clasificados_completo.csv", row.names = TRUE)
```




## Cálculos y resultados

### 5.1 Método Silhouette




### 5.2 Método del Codo (Elbow)




## 5.3 Gap Statistic


```
> gap_stat <- clusGap(datos_norm, FUN = kmeans, nstart = 25, K.max = 10, B
= 50)
Clustering k = 1,2,..., K.max (= 10): .. done
Bootstrapping, b = 1,2,..., B (= 50) [one "." per sample]:
..... 50
Hubo 20 avisos (use warnings() para verlos)
> fviz_gap_stat(gap_stat) +
+   labs(title = "Número óptimo de clusters (Gap Statistic)")
Aviso:
`aes_string()` was deprecated in ggplot2 3.0.0.
i Please use tidy evaluation idioms with `aes()`.
i See also `vignette("ggplot2-in-packages")` for more information.
i The deprecated feature was likely used in the factoextra package.
Please report the issue at
<https://github.com/kassambara/factoextra/issues>.
This warning is displayed once every 8 hours.
Call `lifecycle::last_lifecycle_warnings()` to see where this warning
was generated.
```




## 7. Visualizar los clusters K-means




## 8. K para PAM



## 10. Visualización de PAM



## 12. Visualizar CLARA



## 14. Ver los primeros resultados

```
> head(datos_clasificados)
  PctUrbLo2011Cat PctUrbMd2011Cat PctUrbHi2011Cat
1      1.960000000      0.410000000      0.070000000
2      1.080662675      0.535271287      0.221274640
3      1.460000000      0.390000000      0.140000000
4      7.870907824      2.565590899      0.150917112
5      2.107673796      0.302759772      0.031052284
6      1.894724718      0.656530753      0.017277125

  PctBl2011Cat PctDecid2011Cat PctConif2011Cat
1  0.310000000  30.890000000  18.760000000
2  0.371161541   2.658030847   4.006739440
3  0.440000000  22.720000000  24.910000000
4  0.116090086  28.163454840   3.889017878
5  0.314404378   1.094593021  20.191747860
6  0.207325501  38.712278280  15.831605620

  PctMxFst2011Cat PctShrb2011Cat PctGrs2011Cat
1   7.110000000   2.990000000   3.530000000
2   5.184773898   0.746425826   1.388915481
3   5.820000000   6.660000000   3.950000000
4   6.884142094   0.557232412   1.091246808
5  12.960447150   3.850483251   3.140162248
6  10.544805340   3.530292559   0.702603087

  PctHay2011Cat PctCrop2011Cat PctWdWet2011Cat
1  12.010000000   0.080000000   0.330000000
2   9.611360771   1.120596047  52.953838660
3   5.730000000   1.160000000   1.250000000
4  31.170188070   0.000000000   0.208962155
5   8.422932112   2.429841245   7.301168342
6   1.180603548   0.000000000   0.270674960

  PctHbWet2011Cat PctOw2011ws Ccluster_KMeans
1   0.190000000  3.510000000           3
2   4.679315881  1.877441984           2
3   0.060000000  2.010000000           3
4   0.046436034  5.111680703           3
5   0.683150254  1.005151218           3
6   0.034554250  3.561980270           3

  Ccluster_PAM Ccluster_CLARA
1           1           1
2           1           2
3           1           1
4           1           1
5           1           1
6           1           1
```

## 15. Exportar archivo final

 datos\_clasificados\_completo 22/11/2025 06:27 p. m. Archivo de valores se... 130 KB

## Interpretación detallada por observación

Al analizar los resultados del clustering, se identificaron patrones muy claros en los primeros registros del archivo. La mayoría de las observaciones presentan valores ambientales similares, pero una de ellas destaca marcadamente. La interpretación por método es la siguiente:

### 1. Método K-means

K-means asignó:

- Observación 1 → Cluster 3
- Observación 2 → Cluster 2
- Observación 3 → Cluster 3
- Observación 4 → Cluster 3
- Observación 5 → Cluster 3
- Observación 6 → Cluster 3

Esto muestra que solo la Observación 2 fue colocada en un cluster diferente.

La observación 2 tiene un valor extremadamente alto en PctWdWet2011Cat (52.95%), lo cual la distingue de todas las demás, que tienen valores entre 0.2% y 1.2%.

K-means detectó este comportamiento anómalo y la separó.

### 2. Método PAM

PAM asignó:

- Observaciones 1, 2, 3, 4, 5 y 6 → Cluster 1

Este método considera que todas las observaciones pertenecen al mismo grupo. Esto sucede porque PAM es más robusto ante valores extremos y evita que un solo valor alto genere un cluster propio.

Para PAM, la diferencia de la Observación 2 no es suficiente para separarla.

### 3. Método CLARA

CLARA asignó:

- Observación 1 → Cluster 1
- Observación 2 → Cluster 2
- Observación 3 → Cluster 1
- Observación 4 → Cluster 1
- Observación 5 → Cluster 1
- Observación 6 → Cluster 1

CLARA coincide con K-means en que la Observación 2 forma un patrón diferente.

### Conclusión interpretativa final

En los primeros registros del conjunto de datos, todas las observaciones comparten un perfil ambiental relativamente similar, excepto la Observación 2, que destaca por un porcentaje excepcionalmente alto de humedales. Tanto K-means como CLARA detectaron esta diferencia y la agruparon en un cluster separado, lo que confirma que se trata de un caso especial dentro del conjunto. En contraste, PAM agrupó todas las observaciones juntas, reflejando su naturaleza robusta frente a valores atípicos.

En resumen:

- Observaciones 1, 3, 4, 5 y 6 → Pertenecen al mismo patrón general.
- Observación 2 → Caso único y claramente diferenciado.

## Referencias

- Aggarwal, C. C. (2016). *Data Mining: The textbook*. Springer.