



Universidad Autónoma de Nuevo León

Facultad de Ingeniería Mecánica y Eléctrica

Práctica 5

Clustering

Grupo

507

Asignatura

Tópicos Selectos de Ciencias de
la Ing. III

Docente

Raymundo Said Zamora Pequeño

Fecha

24/05/26

Nombre	Matrícula
Ranfery Josua Peregrina Morales	1924910
Carlos Yair Hernández Hernández	1952660
Karen yareth de Jesús zapata	1955332

Periodo Enero – Junio 2026

Indice

P05: Clustering	4
Objetivo:	4
Marco teórico:	4
Minería de datos	4
Clustering	4
Distancia entre registros y escalamiento	4
Selección del número de clústeres	5
K-means	5
PAM	6
CLARA	6
Aplicación en la práctica	6
Desarrollo:	7
Parte 1 de la práctica 5	7
Parte 2 de la práctica 5	13
Pasos	13
Código Utilizado:	14
Cálculos y resultados:	17
Parte 1	17
Parte 2	29
Selección de variables numéricas	29
Escalamiento de datos	30
Método del codo / WSS	31
Método Silhouette	31
Gap Statistic	31
Selección del número de clústeres	32
Resultado con K-means	32
Resultado con PAM	33
Resultado con CLARA	34

Archivo final con clústeres	35
Conclusión:	36

P05: Clustering

Objetivo:

Encontrar la cantidad de centros de clasificación adecuada para un registro determinado.

Marco teórico:

Minería de datos

La minería de datos es una disciplina que permite analizar conjuntos de datos con el objetivo de descubrir patrones, relaciones o estructuras que no se observan directamente a simple vista. Su finalidad es transformar datos sin procesar en información útil para la interpretación, clasificación y toma de decisiones.

Dentro de la minería de datos existen diferentes técnicas, como clasificación, reglas de asociación, detección de anomalías y agrupamiento. En esta práctica se trabaja con clustering, una técnica de aprendizaje no supervisado que permite dividir un conjunto de registros en grupos de acuerdo con la similitud entre sus características.

Clustering

El clustering, o agrupamiento, es una técnica de aprendizaje no supervisado porque los datos no cuentan con una etiqueta previa que indique a qué grupo pertenece cada registro. En lugar de eso, el algoritmo analiza las características de los datos y forma grupos automáticamente.

El objetivo principal del clustering es que los elementos dentro de un mismo grupo sean lo más similares posible entre sí, mientras que los elementos de grupos diferentes sean lo más distintos posible. En esta práctica, el clustering se utilizó para agrupar canciones de Spotify de acuerdo con características musicales numéricas como duración, popularidad, energía, acústica, instrumentalidad, valencia y tempo.

Distancia entre registros y escalamiento

Los algoritmos de clustering trabajan principalmente con variables numéricas, ya que necesitan medir la distancia entre los registros. Cada canción puede interpretarse como un punto dentro de un espacio de varias dimensiones, donde cada dimensión representa una variable del dataset.

Una de las medidas más utilizadas para comparar registros es la distancia euclidiana, la cual representa la distancia en línea recta entre dos puntos. Mientras menor sea la distancia entre dos canciones, mayor será su similitud.

Antes de aplicar los algoritmos, es necesario escalar los datos. Esto se debe a que las variables pueden manejar rangos muy diferentes. Por ejemplo, la duración de una canción se mide en milisegundos y puede tener valores grandes, mientras que variables como danceability, energy o valence manejan valores pequeños. Si no se realiza el escalamiento, una variable con valores más grandes puede dominar el cálculo de distancia.

En esta práctica se utilizó la función `scale()` en RStudio para transformar las variables numéricas y colocarlas en una escala comparable. De esta forma, cada característica musical pudo aportar de manera más equilibrada al proceso de agrupamiento.

Selección del número de clústeres

Uno de los pasos más importantes en clustering es decidir cuántos grupos se van a formar. Si se seleccionan muy pocos clústeres, la clasificación puede ser demasiado general. Si se seleccionan demasiados, los grupos pueden ser difíciles de interpretar.

Para apoyar esta decisión se utilizaron tres métodos: método del codo o WSS, método Silhouette y Gap Statistic.

El método del codo analiza la suma de cuadrados dentro de los grupos. Conforme aumenta el número de clústeres, el error disminuye, pero llega un punto donde agregar más grupos ya no mejora significativamente el resultado. Ese punto se conoce como “codo”.

El método Silhouette evalúa qué tan bien agrupado se encuentra cada registro dentro de su clúster. Un valor más alto indica que los elementos están mejor separados y que los registros dentro de cada grupo son más similares entre sí.

El Gap Statistic compara la estructura de los datos reales contra una distribución aleatoria. Su objetivo es identificar si los grupos encontrados tienen una separación significativa o si podrían aparecer por casualidad.

En esta práctica se compararon estos tres métodos y, siguiendo la lógica vista en clase, se decidió trabajar con 3 clústeres, ya que esta cantidad permite dividir las canciones en grupos interpretables.

K-means

K-means es un algoritmo de clustering basado en centroides. Un centroide representa el punto promedio de un grupo. El algoritmo asigna cada registro al centroide más cercano y después recalcula los centroides con base en los elementos asignados a cada grupo.

Este proceso se repite hasta que los centroides dejan de cambiar de forma significativa. En la práctica se aplicó K-means con 3 clústeres para agrupar las canciones latinas de Spotify según sus características musicales.

PAM

PAM significa Partitioning Around Medoids. Este algoritmo es parecido a K-means, pero en lugar de utilizar centroides calculados como promedios, utiliza medoides. Un medoide es un registro real del dataset que funciona como representante de un grupo.

La ventaja de PAM es que el centro del grupo corresponde a una instancia existente, no a un punto calculado. Esto puede hacerlo más resistente ante valores atípicos. En esta práctica se aplicó PAM con 3 clústeres para comparar su resultado con K-means.

CLARA

CLARA es una variante de PAM diseñada para trabajar con conjuntos de datos más grandes mediante muestreo. En lugar de analizar todos los registros al mismo tiempo, utiliza muestras del conjunto de datos para encontrar medoides representativos.

Aunque en esta práctica se trabajó con una muestra de 50 canciones, se aplicó CLARA para seguir el procedimiento visto en clase y comparar su comportamiento con K-means y PAM.

Aplicación en la práctica

En esta práctica se utilizó un dataset de canciones de Spotify. Primero se filtraron canciones relacionadas con géneros latinos y después se tomó una muestra de 50 registros. Posteriormente, se seleccionaron variables numéricas, se escalaron los datos y se analizaron diferentes métodos para decidir la cantidad adecuada de clústeres.

Finalmente, se aplicaron los algoritmos K-means, PAM y CLARA con 3 clústeres. Cada algoritmo generó una clasificación distinta de las canciones de acuerdo con su similitud. Además, se agregaron al dataset final columnas con el clúster asignado por cada método, lo que permitió comparar cómo se agruparon las canciones latinas según sus características musicales.

Desarrollo:

Parte 1 de la práctica 5

Dado un Data set **ca_cest_brandi_carlile.csv** con datos sobre canciones con los registros ilustrados en la siguiente imagen:

Duration (ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumental	Liveness	Valence	Tempo
265306	60	0.452	0.329	8	-12.382	0.0425	0.942	0.00128	0.0979	0.198	82.767
268653	71	0.297	0.839	7	-4.448	0.0848	0.399	0	0.0965	0.303	152.997
231000	68	0.503	0.722	9	-7.595	0.103	0.205	0.0000352	0.0845	0.354	172.006
238493	66	0.544	0.5	11	-8.253	0.026	0.0325	0.00000378	0.109	0.177	93.621
230098	62	0.568	0.686	1	-6.635	0.033	0.15	0.00000181	0.0881	0.725	172.075
214666	61	0.564	0.209	3	-8.922	0.0317	0.724	0.0000399	0.107	0.402	109.024
209906	58	0.559	0.562	11	-5.674	0.0325	0.203	0.00000948	0.17	0.428	132.062
279373	58	0.236	0.578	7	-5.477	0.0404	0.327	0.00015	0.206	0.227	75.367
206267	58	0.606	0.326	10	-10.031	0.0294	0.841	0	0.139	0.414	91.626
152946	53	0.638	0.452	9	-9.616	0.0297	0.608	0.0577	0.112	0.341	100.105

Se nos pidió identificar elementos correspondientes a dos grupos distintos. Para obtener dos grupos notablemente diferentes a partir de una característica, consideramos cada característica (columna) como una lista de datos, y en cada dato seleccionamos los dos más diferentes posibles, en este caso, dos opuestos: **Mínimos y Máximos** de cada “lista” (columna).

Y la idea es identificar qué datos se acercan más a pertenecer a un grupo, si se parecen más al grupo de **Mínimos** o al de **Máximos**. Pero pronto pierde el sentido denotarlos *máximos y mínimos*, entonces los llamaremos **C0** y **C1**, respectivamente. La selección de los valores máximos y mínimos no fue arbitraria, sino que sirvió para definir los **centroides iniciales** (o perfiles ideales) de nuestros clusters.

Sin embargo, por la naturaleza inicial de los datos, podemos ver que hay valores con rangos muy distintos. Algunos son datos entre 0 y 1, otros son datos negativos, otros son datos que se cuentan por decenas. Y si tuviéramos que agrupar datos por características pero cada columna usa valores de característica tan distintos, terminaríamos con grupos de coordenadas imprecisas y muy lejanos, que no necesariamente se refieren a la misma tendencia de Mínimos y Máximos. Así que hemos *normalizado* el rango de valores entre 0 y 1 utilizando la técnica de **Línea recta**.

Este método toma los datos de cualquier columna y los ajusta proporcionalmente para que el valor más bajo sea un 0 exacto, el valor más alto sea un 1 exacto, y todos los demás queden en medio manteniendo su distancia relativa (como en una línea recta)

Y repetimos para cada fila de la tabla original. Para obtener de cada fila la distancia con el centro del grupo correspondiente. En este caso, es el mínimo. Para después repetir el proceso, pero esta vez tomando como datos del centro, los datos del máximo.

- Como primer objeto tomamos: El valor de esa columna para la fila con la que estemos trabajando.
- Como segundo objeto tomamos: El valor del máximo asociado a esa columna entera.

También de igual manera, repetimos para cada fila hasta tener todas las filas de la tabla normalizada.

Esta tabla indica para cada fila su distancia general con los respectivos centros. Lo que es nuestro primer acercamiento para decidir a qué centro está más cerca. Es decir, respecto a cuál centro la distancia es menor. Comparando para cada fila los valores y eligiendo el menor, el que expresa la menor distancia.

Obtenemos para cada fila la menor distancia y comparamos a qué grupo pertenece. Y creamos una segunda tabla auxiliar a la derecha, en donde expresamos esa pertenencia, con un “0” si no pertenece a ese Cluster, y con un “1” si pertenece. Como podemos apreciar, exceptuando el segundo y tercer dato, todos los demás datos están más cerca del centro de C0 que del centro de C1.

DC0	DC1	Distancia a grupo más cercano	C0	C1
1.645418546	2.397252086	1.645418546	1	0
2.260886111	1.958213892	1.958213892	0	1
2.259361211	1.897547601	1.897547601	0	1
1.737292491	2.443812722	1.737292491	1	0
2.042052171	2.209134944	2.042052171	1	0
1.532076948	2.350248922	1.532076948	1	0
1.908418579	2.112590783	1.908418579	1	0
1.608706290	2.400436277	1.608706290	1	0
1.788463159	2.259151545	1.788463159	1	0
1.877280664	2.151982956	1.877280664	1	0
1.790573988	2.088210542	1.790573988	1	0
1.612464719	2.304836950	1.612464719	1	0

Ahora que identificamos como “1” los datos que corresponden a cada fila y como “0” los que no, podemos eliminar mediante la multiplicación de los respectivos “0”s (con ayuda de una =SUMAPRODUCTO) todos los datos que no corresponden a nuestro Cluster en cada columna. Comenzando por “Durability” en este caso, y ubicándola en una nueva fila de C0, en una nueva columna correspondiente a esa columna.

Para así crear un nuevo centro correspondiente al Cluster con el que estamos trabajando. Iniciando por el C0, sumamos todos los datos correspondientes a C0 (Y solo correspondientes a C0) e incluimos por separado el dato asociado al centro anterior. Y lo dividimos entre la cantidad de elementos, incluyendo también el dato asociado al centro anterior. Esta operación de “Sumar todo y Dividir entre los elementos” es un promedio. Es decir, nuestro nuevo centro es el promedio de los datos asociados al Cluster indicado.

Mn	Cn	Nuevos centros										C0	C1
		Duration (ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumentalness	Liveness	Valence	Tempo
1.645418546	2.397252086	1.645418546	2.397252086	1.645418546	2.397252086	1.645418546	2.397252086	1.645418546	2.397252086	1.645418546	2.397252086	1.645418546	2.397252086
2.260886111	1.958213892	2.260886111	1.958213892	2.260886111	1.958213892	2.260886111	1.958213892	2.260886111	1.958213892	2.260886111	1.958213892	2.260886111	1.958213892
2.259361211	1.897547601	2.259361211	1.897547601	2.259361211	1.897547601	2.259361211	1.897547601	2.259361211	1.897547601	2.259361211	1.897547601	2.259361211	1.897547601
1.737292491	2.443812722	1.737292491	2.443812722	1.737292491	2.443812722	1.737292491	2.443812722	1.737292491	2.443812722	1.737292491	2.443812722	1.737292491	2.443812722
2.042052171	2.209134944	2.042052171	2.209134944	2.042052171	2.209134944	2.042052171	2.209134944	2.042052171	2.209134944	2.042052171	2.209134944	2.042052171	2.209134944
1.532076948	2.350248922	1.532076948	2.350248922	1.532076948	2.350248922	1.532076948	2.350248922	1.532076948	2.350248922	1.532076948	2.350248922	1.532076948	2.350248922
1.908418579	2.112590783	1.908418579	2.112590783	1.908418579	2.112590783	1.908418579	2.112590783	1.908418579	2.112590783	1.908418579	2.112590783	1.908418579	2.112590783
1.608706290	2.400436277	1.608706290	2.400436277	1.608706290	2.400436277	1.608706290	2.400436277	1.608706290	2.400436277	1.608706290	2.400436277	1.608706290	2.400436277
1.788463159	2.259151545	1.788463159	2.259151545	1.788463159	2.259151545	1.788463159	2.259151545	1.788463159	2.259151545	1.788463159	2.259151545	1.788463159	2.259151545
1.877280664	2.151982956	1.877280664	2.151982956	1.877280664	2.151982956	1.877280664	2.151982956	1.877280664	2.151982956	1.877280664	2.151982956	1.877280664	2.151982956
1.790573988	2.088210542	1.790573988	2.088210542	1.790573988	2.088210542	1.790573988	2.088210542	1.790573988	2.088210542	1.790573988	2.088210542	1.790573988	2.088210542
1.612464719	2.304836950	1.612464719	2.304836950	1.612464719	2.304836950	1.612464719	2.304836950	1.612464719	2.304836950	1.612464719	2.304836950	1.612464719	2.304836950

Repetimos lo mismo para el Cluster C1. Promediamos todos los datos correspondientes a C1 para obtener un nuevo centro de esa columna, y seguimos ubicando los de las siguientes columnas.

Esto nos dejará con una nueva lista de centros para cada columna correspondientes a C0 y C1. Y lo que sigue, es repetir el mismo proceso utilizando la misma tabla normalizada de datos:

1. Comparar para cada fila la distancia euclidiana al nuevo centro de C0 y C1
2. Identificar cuál distancia es menor

3. Separar los que quedaron más cerca a C0 y C1
4. Suma producto para promediar solo los datos de C0 en cada columna
5. Suma producto para promediar solo los datos de C1 en cada columna
6. Y obtener nuevos centros de cada columna para C0 y C1

Y con esos nuevos centros volver a repetir ese proceso. En cara repetición del proceso, lo normal es que la distancia total entre los datos y su centro asociado, sea cada vez menor. Y dejaremos de repetir este proceso hasta que no haya un cambio significativo. En este caso, en nuestro caso fueron 3 repeticiones.

C0	C1	Distancia a grupo más cercano	C0	C1	C0	C1	Distancia a grupo m	C0	C1	C0	C1	Distancia Min	C0	C1
1.645418546	2.597252086	1.645418546	1	0	0.843350900	1.628720684	0.843350900	1	0	0.845379118	1.628720684	0.845379118	1	0
2.260886111	1.958213862	1.958213862	0	1	1.254209136	0.751603809	0.751603809	0	1	1.243228696	0.751603809	0.751603809	0	1
2.259361211	1.897547601	1.897547601	0	1	1.243047833	0.697808500	0.697808500	0	1	1.231797611	0.697808500	0.697808500	0	1
1.737292491	2.443811722	1.737292491	1	0	0.948790490	1.510261887	0.948790490	1	0	0.950324288	1.510261887	0.950324288	1	0
2.042623171	2.289134844	2.042623171	1	0	1.159129256	1.302092426	1.159129256	1	0	1.153430122	1.302092426	1.153430122	1	0
1.532076948	2.350248922	1.532076948	1	0	0.658548830	1.573723088	0.658548830	1	0	0.662392209	1.573723088	0.662392209	1	0
1.908418579	2.112590783	1.908418579	1	0	0.727174926	1.216730461	0.727174926	1	0	0.714049126	1.216730461	0.714049126	1	0
1.608706290	2.400436277	1.608706290	1	0	0.862375279	1.447024794	0.862375279	1	0	0.886423984	1.447024794	0.886423984	1	0
1.786461159	2.259151455	1.786461159	1	0	0.696951778	1.568630657	0.696951778	1	0	0.689611235	1.568630657	0.689611235	1	0
1.877280664	2.151983956	1.877280664	1	0	1.079328657	1.670193669	1.079328657	1	0	1.077550020	1.670193669	1.077550020	1	0
1.790573988	2.088210542	1.790573988	1	0	0.525535538	1.235157777	0.525535538	1	0	0.510819529	1.235157777	0.510819529	1	0
1.612464719	2.304830950	1.612464719	1	0	0.493553365	1.452348093	0.493553365	1	0	0.489708399	1.452348093	0.489708399	1	0
1.312990181	2.481724852	1.312990181	1	0	0.495214764	1.577172881	0.495214764	1	0	0.509892747	1.577172881	0.509892747	1	0
1.335320655	2.610204966	1.335320655	1	0	0.931187044	1.783040958	0.931187044	1	0	0.944530685	1.783040958	0.944530685	1	0
1.456141635	2.652157877	1.456141635	1	0	1.118425070	1.941721358	1.118425070	1	0	1.129970576	1.941721358	1.129970576	1	0
1.537010860	2.346476358	1.537010860	1	0	0.550749050	1.491842376	0.550749050	1	0	0.552712675	1.491842376	0.552712675	1	0
1.747765462	2.139607299	1.747765462	1	0	0.482635194	1.326370855	0.482635194	1	0	0.478072384	1.326370855	0.478072384	1	0
2.006268144	2.141225252	2.006268144	1	0	0.937483942	1.377924354	0.937483942	1	0	0.927027608	1.377924354	0.927027608	1	0
1.655893587	2.295994232	1.655893587	1	0	0.914748725	1.384198401	0.914748725	1	0	0.917610596	1.384198401	0.917610596	1	0
1.161636362	2.561246315	1.161636362	1	0	0.636298355	1.715992764	0.636298355	1	0	0.655235431	1.715992764	0.655235431	1	0
1.996353936	2.282479453	1.996353936	1	0	0.861915725	1.478474854	0.861915725	1	0	0.869940749	1.478474854	0.869940749	1	0
1.531325350	2.654573878	1.531325350	1	0	0.962012610	1.915188435	0.962012610	1	0	1.000110394	1.915188435	1.000110394	1	0
1.420210550	2.463465831	1.420210550	1	0	0.641197119	1.529515100	0.641197119	1	0	0.644895993	1.529515100	0.644895993	1	0
1.703334040	2.226615218	1.703334040	1	0	0.657928711	1.281879003	0.657928711	1	0	0.653338818	1.281879003	0.653338818	1	0
1.918357380	2.2369897456	1.918357380	1	0	0.876343150	1.391962751	0.876343150	1	0	0.867803725	1.391962751	0.867803725	1	0
1.604302742	2.327118911	1.604302742	1	0	0.501455488	1.512271218	0.501455488	1	0	0.498355496	1.512271218	0.498355496	1	0
1.633074374	2.500271164	1.633074374	1	0	0.975620304	1.599197333	0.975620304	1	0	0.979881860	1.599197333	0.979881860	1	0
1.681098069	2.148902161	1.681098069	1	0	0.587709330	1.293777100	0.587709330	1	0	0.582354557	1.293777100	0.582354557	1	0
1.516882630	2.371473493	1.516882630	1	0	0.501721090	1.399826415	0.501721090	1	0	0.504071639	1.399826415	0.504071639	1	0
1.729967227	2.254863057	1.729967227	1	0	0.469241041	1.466407476	0.469241041	1	0	0.477112714	1.466407476	0.477112714	1	0
1.467450330	2.386460967	1.467450330	1	0	0.592776366	1.564465884	0.592776366	1	0	0.597900450	1.564465884	0.597900450	1	0
1.837651991	2.219202949	1.837651991	1	0	0.683370058	1.345693477	0.683370058	1	0	0.672416221	1.345693477	0.672416221	1	0
1.765465908	2.245614503	1.765465908	1	0	0.726432687	1.404770051	0.726432687	1	0	0.726020084	1.404770051	0.726020084	1	0
1.773179318	2.227877478	1.773179318	1	0	0.806398921	1.220368339	0.806398921	1	0	0.802340232	1.220368339	0.802340232	1	0
1.951895452	2.364981207	1.951895452	1	0	0.692943859	1.713895425	0.692943859	1	0	0.696400293	1.713895425	0.696400293	1	0
1.671295466	2.370685841	1.671295466	1	0	0.769841180	1.699324066	0.769841180	1	0	0.769410373	1.699324066	0.769410373	1	0
1.686573740	2.345853774	1.686573740	1	0	0.944191961	1.540635513	0.944191961	1	0	0.946459799	1.540635513	0.946459799	1	0
1.623907629	2.531999564	1.623907629	1	0	0.805301221	1.851402226	0.805301221	1	0	0.807519090	1.851402226	0.807519090	1	0
1.951322516	2.320597966	1.951322516	1	0	1.298113203	1.935931320	1.298113203	1	0	1.298458700	1.935931320	1.298458700	1	0
1.990954937	2.234957377	1.990954937	1	0	1.079173063	1.464259200	1.079173063	1	0	1.073301962	1.464259200	1.073301962	1	0
1.702884444	2.503334198	1.702884444	1	0	0.826694657	1.863157249	0.826694657	1	0	0.826102034	1.863157249	0.826102034	1	0
1.728800227	2.291480008	1.728800227	1	0	0.929341444	1.494856763	0.929341444	1	0	0.929793603	1.494856763	0.929793603	1	0
1.955484504	2.369963879	1.955484504	1	0	0.865958394	1.636767522	0.865958394	1	0	0.878622617	1.636767522	0.878622617	1	0
1.976609309	2.224286584	1.976609309	1	0	1.209885569	1.422380535	1.209885569	1	0	1.207801666	1.422380535	1.207801666	1	0
1.832363826	2.235078477	1.832363826	1	0	0.836209695	1.357574871	0.836209695	1	0	0.830317160	1.357574871	0.830317160	1	0
1.509802008	2.518553099	1.509802008	1	0	0.831318937	1.670603917	0.831318937	1	0	0.838252890	1.670603917	0.838252890	1	0
1.859973777	2.378887209	1.859973777	1	0	0.909059193	1.798151695	0.909059193	1	0	0.903921834	1.798151695	0.903921834	1	0
1.591369335	2.574128330	1.591369335	1	0	1.011515846	1.870459091	1.011515846	1	0	1.007866607	1.870459091	1.007866607	1	0
1.548183068	2.361788145	1.548183068	1	0	0.488236160	1.530639189	0.488236160	1	0	0.488418841	1.530639189	0.488418841	1	0
1.820286698	2.286140598	1.820286698	1	0	1.222899342	1.744389146	1.222899342	1	0	1.225845202	1.744389146	1.225845202	1	0
1.717230817	2.395832946	1.717230817	1	0	0.768780295	1.699611802	0.768780295	1	0	0.766299102	1.699611802	0.766299102	1	0

Distancia asociada entre
objetos y centros:
86.92969653

Distancia asociada entre
objetos y centros:
41.054823621

Distancia asociada entre
objetos y centros:
41.014704846

Nuestro último paso con Clúster fue identificar el objeto de menor distancia de cada grupo.

- De C0 fue 0.477112714
- De C1 fue 0.697808500

Ahora lo que sigue es identificar **Medoides**.

Un **medoide** es el objeto dentro de un clúster cuya disimilitud con todos los demás objetos del grupo es mínima.

A diferencia de los **centroides** (que son promedios y pueden dar como resultado un valor que no existe en la vida real, como una canción con "0.543 de popularidad"), los **medoides siempre son puntos reales del dataset**. Son el "representante" o la "canción típica" de cada grupo.

Al buscar el objeto con la menor distancia al centro promediado (0.477 para C0 y 0.697 para C1), lo que hicimos fue identificar qué canción real se parece más al "ideal" matemático calculado.

Una vez estabilizados los grupos, transitamos hacia un modelo de **K-Medoides** para otorgar mayor interpretabilidad a los resultados. Para ello, identificamos los **medoides** de cada clúster: las canciones reales con la menor distancia respecto a los centros promediados (con valores de 0.4771 para C0 y 0.6978 para C1). Al utilizar estos objetos reales como nuevos centros en lugar de promedios abstractos, buscamos validar la cohesión de los grupos basándonos en ejemplares existentes en el dataset, asegurando que la segmentación final no solo fuera matemáticamente óptima, sino también representativa de casos reales dentro de la muestra.

[illegible]

Aquí cada iteración no incluye el centro como un dato más, si no que se considera dentro del promedio y se identifica como centro el valor con menor distancia al centro.

Y este proceso se repite nuevamente, hasta que deje de haber cambio en el número de miembros que pertenecen a cada grupo, y no hasta que la suma de distancias sea parecida entre iteraciones.

Nuevos Centroides	Min	0.404133674	0.300841515	0.520408163	0.45258633	0.640316206	0.565671203	0.186271205	0.592286406	0.053416543	0.137362878	0.372896858	0.436389727
	Max	0.415112916	0.670967742	0.617959184	0.872648336	0.363636364	0.765207745	0.56873385	0.245812729	0.000192724	0.071111751	0.618940969	0.640674846
Nuevos Centroides	Min	0.403966223	0.314516129	0.536020408	0.421421523	0.697727273	0.531529851	0.177196382	0.636809433	0.061422583	0.132222062	0.325263958	0.387729341
	Max	0.409733152	0.419354839	0.507977737	0.756850175	0.305785124	0.780520004	0.393117219	0.272896455	0.000111024	0.125942606	0.657945638	0.706193457
Nuevos Centroides	Min	0.398459605	0.313242784	0.547744361	0.408315388	0.700956938	0.523078066	0.174418605	0.653142867	0.064502702	0.134451552	0.322377893	0.363806015
	Max	0.424942201	0.406947891	0.478021978	0.74355601	0.356643357	0.766919043	0.368018287	0.281139183	0.000540148	0.120391705	0.61520003	0.727128698
Nuevos Centroides	Min	0.403049603	0.324324324	0.536514065	0.39107941	0.702702703	0.513499886	0.177945387	0.691305279	0.039218991	0.132262735	0.302636983	0.373288003
	Max	0.40840946	0.352822581	0.526913265	0.710317721	0.431818182	0.768410902	0.319848191	0.285126549	0.06293887	0.119239631	0.595464726	0.663468051
Nuevos Centroides	Min	0.42415769	0.320625611	0.524427953	0.353470237	0.691460055	0.480518171	0.176258711	0.748111197	0.043967286	0.133138703	0.293199149	0.372270992
	Max	0.383813207	0.374193548	0.539489796	0.708656756	0.5	0.743767648	0.297932817	0.280980486	0.051423331	0.121054147	0.548392257	0.584321464
Nuevos Centroides	Min	0.400006601	0.309438471	0.531897203	0.302962086	0.666666667	0.415142755	0.18437171	0.822288391	0.052258909	0.140302313	0.312992884	0.380616039
	Max	0.411063974	0.36827957	0.527806122	0.708426523	0.553030303	0.776585821	0.268087855	0.261352156	0.043630586	0.120253696	0.491548019	0.541694525
Nuevos Centroides	Min	0.399396667	0.312655087	0.52833595	0.289056096	0.660839161	0.403167375	0.175014908	0.838317157	0.054248166	0.131718584	0.315980212	0.387706548
	Max	0.41125601	0.362580645	0.531673469	0.706670175	0.563636364	0.774582493	0.274470284	0.267119689	0.04190689	0.129982719	0.481298992	0.527877257

Los datos están ilustrados con más detalle en la sección de cálculos y resultados.

Parte 2 de la práctica 5

En esta segunda parte de la práctica se trabajó con un dataset diferente al de clase. El objetivo fue aplicar algoritmos de clustering sobre un conjunto de datos con variables numéricas para identificar grupos de canciones con características similares.

Para esta parte se utilizó el archivo `spotifydataset.csv`, obtenido de Kaggle. Este dataset contiene información de canciones de Spotify, incluyendo datos del artista, género musical, popularidad y características musicales. Como el archivo original contenía canciones de distintos géneros, se decidió trabajar únicamente con canciones relacionadas con géneros latinos.

Pasos

1. Se cargaron las librerías necesarias para realizar el análisis de clustering y la manipulación de datos.
2. Se importó el dataset original en RStudio para revisar su contenido.
3. Se exploró la estructura del dataset, verificando la cantidad de registros, variables disponibles y nombres de columnas.
4. Se identificó que el dataset original contenía 1000 registros y 23 variables.
5. Debido a que el dataset contenía canciones de diferentes géneros, se filtraron únicamente las canciones relacionadas con géneros latinos.
6. Para el filtrado se utilizaron palabras clave dentro de la columna de géneros, como: latin, reggaeton, bachata, urbano, tropical y mexican.
7. Después del filtrado se obtuvo un subconjunto de 90 canciones latinas.
8. Para trabajar con una cantidad de datos más parecida al ejemplo visto en clase, se tomó una muestra aleatoria de 50 canciones.
9. La muestra de 50 canciones fue guardada como un nuevo archivo llamado `spotify_latinos_50.csv`.

10. Posteriormente, se cargó el archivo `spotify_latinos_50.csv` como dataset principal de trabajo.
11. Se revisó nuevamente la estructura del nuevo dataset para comprobar que los datos se hubieran guardado correctamente.
12. Se seleccionaron únicamente variables numéricas, ya que los algoritmos de clustering trabajan con distancias entre valores numéricos.
13. Las variables seleccionadas fueron características musicales como duración, popularidad, energía, tempo, acústica, instrumentalidad, valencia, entre otras.
14. Se aplicó escalamiento a las variables numéricas para que todas quedaran en una escala comparable.
15. El escalamiento fue necesario porque algunas variables tienen valores grandes, como la duración en milisegundos, mientras que otras tienen valores pequeños, como `danceability`, `energy` o `valence`.
16. Una vez preparados los datos, se aplicaron tres métodos para analizar la cantidad adecuada de clústeres: método del codo, método Silhouette y Gap Statistic.
17. Con base en las gráficas obtenidas y siguiendo la lógica vista en clase, se seleccionó una cantidad de clústeres para realizar la clasificación.
18. Se aplicó el algoritmo K-means, el cual agrupa los datos usando centroides.
19. Después se aplicó el algoritmo PAM, el cual utiliza medoides, es decir, registros reales del dataset como representantes de cada grupo.
20. También se aplicó el algoritmo CLARA, que es una variante de PAM diseñada para trabajar con conjuntos de datos más grandes mediante muestreo.
21. Finalmente, se agregaron al dataset tres nuevas columnas con los clústeres asignados por cada algoritmo.
22. El archivo final fue guardado como `spotify_latinos_clustering.csv`.
23. Con este procedimiento se obtuvo un dataset reducido, preparado y clasificado mediante tres algoritmos de clustering, permitiendo comparar cómo se agrupan las canciones latinas según sus características musicales.

Código Utilizado:

```
library(cluster)

library(factoextra)

library(tidyverse)

# Cargar dataset original

datos_original <- read.csv("spotifydataset.csv")

View(datos_original)
```

```
str(datos_original)
colnames(datos_original)
# Filtrar canciones latinas
datos_latinos <- datos_original %>%
  filter(grepl("latin|reggaeton|bachata|urbano|tropical|mexican", genres, ignore.case =
TRUE))
View(datos_latinos)
nrow(datos_latinos)
# Tomar muestra de 50 canciones
set.seed(123)
datos_latinos_50 <- datos_latinos %>%
  sample_n(50)
View(datos_latinos_50)
# Guardar nuevo dataset pequeño
write.csv(datos_latinos_50, "spotify_latinos_50.csv", row.names = FALSE)
# Cargar el nuevo dataset
datos <- read.csv("spotify_latinos_50.csv")
View(datos)
str(datos)
colnames(datos)
# Seleccionar variables numéricas para clustering
datos_num <- datos %>%
  select(duration_ms, track_popularity, danceability, energy, key, loudness,
  speechiness, acousticness, instrumentalness, liveness, valence, tempo)
View(datos_num)
summary(datos_num)
# Escalar datos
```

```
datos_scaled <- scale(datos_num)
View(datos_scaled)
# Método del codo / WSS
fviz_nbclust(datos_scaled, kmeans, method = "wss")
# Método Silhouette
fviz_nbclust(datos_scaled, kmeans, method = "silhouette")
# Gap Statistic
gap_stat <- clusGap(datos_scaled, FUN = kmeans, nstart = 25, K.max = 10, B = 50)
fviz_gap_stat(gap_stat)
# K-means con 3 clústeres
set.seed(123)
km <- kmeans(datos_scaled, centers = 3, nstart = 25)
fviz_cluster(km, data = datos_scaled)
km
# PAM con 3 clústeres
pam_res <- pam(datos_scaled, k = 3)
fviz_cluster(pam_res, data = datos_scaled)
pam_res
# CLARA con 3 clústeres
clara_res <- clara(datos_scaled, k = 3)
fviz_cluster(clara_res, data = datos_scaled)
clara_res
# Agregar clústeres al dataset
datos$cluster_kmeans <- km$cluster
datos$cluster_pam <- pam_res$clustering
datos$cluster_clara <- clara_res$clustering
View(datos)
```

Guardar archivo final con clústeres

```
write.csv(datos, "spotify_latinos_clustering.csv", row.names = FALSE)
```

Cálculos y resultados:

Parte 1

Dado un dataset inicial con valores en rangos muy distintos para cada característica (Columna) lo inicial fue normalizar utilizando línea recta.

Para terminar con una tabla idéntica en tamaño pero con los valores entre 0 y 1, hicimos lo siguiente

Paso 1: Preparamos la nueva tabla Copiando los encabezados de tu tabla original (Duración, Popularidad, Danceabilidad, etc.) y pegándolos en un espacio en blanco a la derecha de los datos actuales.

Paso 2: Escribimos la fórmula: Por ejemplo, tomando en cuenta que originalmente nuestro primer dato de la columna "Popularidad" estaba en la celda **B2** y que los datos terminan en la fila **51** (celda B51).

Ve a la primera celda vacía debajo del encabezado de "Popularidad" en tu *nueva* tabla y escribe la siguiente fórmula:

$$=(B2 - \text{MIN}(B\$2:B\$51)) / (\text{MAX}(B\$2:B\$51) - \text{MIN}(B\$2:B\$51))$$

Es necesario haber puesto el signo \$ antes de los números de las filas en las funciones MIN y MAX. Esto "congela" el rango de búsqueda para que, al copiar la fórmula hacia abajo, Excel siempre busque el mínimo y máximo en la columna completa, en lugar de ir bajando el rango.

Paso 3: Arrastramos hacia abajo Presionar *Enter*. Ese primer valor ahora es ahora un número entre 0 y 1. Seleccionamos esa celda, y hacemos clic en el pequeño cuadrado verde en la esquina inferior derecha y arrastramos hacia abajo hasta llegar a la última fila.

Paso 4: Arrastramos hacia la derecha Con toda esa nueva columna seleccionada arrastramos ese mismo cuadrado verde hacia la derecha para rellenar las columnas de "Duración", "Danceabilidad", etc. Como no le pusimos un signo \$ a las letras de las columnas (las "B"), Excel es inteligente y cambiará automáticamente la fórmula a las columnas C, D, E, etc., calculando los mínimos y máximos de cada nueva variable por separado.

Listo, ahora cada columna tiene sus valores expresados de 0 a 1 en relación a su máximo y mínimo local.

Duración(ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumentalness	Liveness	Valence	Tempo	Duración(ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumentalness	Liveness	Valence	Tempo
263386	65	0.453	0.329	8	-12.382	0.0425	0.142	0.09138	0.0978	0.198	82.787	0.93093888	0.64531290	0.44883327	0.2363653	0.77772727	0.81819568	0.23284823	1.00000000	0.01263458	0.87676801	0.13953480	0.11314874
268653	71	0.297	0.839	7	-4.448	0.0848	0.389	0	0.0965	0.303	152.987	0.59954636	1.00000000	0.12448976	0.76465781	0.42255541	0.00000000	0.00000000	0.87474078	0.32498815	0.72889816	0.28598816	
231100	68	0.503	0.722	9	-7.595	0.103	0.205	0.0000302	0.0845	0.354	172.006	0.42011908	0.90322580	0.54489759	0.84607285	0.81818181	0.64471961	1.00000000	0.00058478	0.61405677	0.40648481	0.60401477	
238453	66	0.544	0.5	11	-5.253	0.106	0.8225	0.0000378	0.109	0.177	93.621	0.45482578	0.93879877	0.62887429	0.54540602	1.00000000	0.37933029	0.00187959	0.83388834	0.00002761	0.80271195	0.12334396	
230098	62	0.588	0.686	1	-6.625	0.033	0.15	0.0000181	0.0881	0.725	172.075	0.41861728	0.70967419	0.67570520	0.78871086	0.09090901	0.74152864	0.05607235	0.13776008	0.00002066	0.00000000	1.00000000	
214668	61	0.564	0.259	3	-8.022	0.0317	0.724	0.0000399	0.107	0.402	109.024	0.34227745	0.67743505	0.86888775	0.17116168	0.72772727	0.51089149	0.87081159	0.74817426	0.00002761	0.86888175	0.44828275	
209096	58	0.559	0.562	11	-5.674	0.0325	0.203	0.0000048	0.17	0.428	132.062	0.31958475	0.50846161	0.65018873	0.83574267	1.00000000	0.83842921	0.08947267	0.71411261	0.00015745	0.18889758	0.32487829	
279373	58	0.236	0.578	7	-5.477	0.0484	0.327	0.00015	0.206	0.227	79.367	0.65063174	0.50866351	0.60000000	0.658624128	0.63636368	0.85839882	0.19124470	0.34888886	0.00048164	0.30327468	0.60488497	
208267	58	0.696	0.326	10	-10.031	0.0294	0.841	0	0.138	0.414	93.626	0.30252347	0.80646161	0.79510241	0.53288884	0.90909099	0.80909097	0.89259313	0.00000000	0.32044738	0.16547963	0.19607171	
152948	53	0.628	0.452	9	-9.036	0.0297	0.608	0.0577	0.112	0.341	100.195	0.84813897	0.41034839	0.82684663	0.48888446	0.81818181	0.44000000	0.82971578	0.644813102	0.958471761	0.80792212	0.38989898	
215480	47	0.554	0.47	8	-8.604	0.048	0.77	0.0000026	0.106	0.348	98.98	0.33188832	0.84387907	0.64897892	0.51433781	0.77772727	0.744855193	0.37726982	0.81788982	0.00004189	0.08842189	0.39369708	
241146	54	0.377	0.53	7	-6.749	0.0312	0.144	0.0000029	0.103	0.27	85.471	0.46466120	0.45162903	0.48983687	0.35847542	0.63636368	0.7003271	0.87231421	0.97873237	0.00005451	0.88413182	0.81312939	
185228	53	0.419	0.269	7	-8.388	0.0356	0.628	0.000183	0.116	0.152	121.895	0.20199477	0.41034839	0.37348898	0.25088671	0.63636368	0.46389733	0.12938886	0.66395410	0.00007032	0.80334665	0.471752208	
295958	53	0.334	0.298	0	-11.709	0.0803	0.779	0.00021	0.0909	0.302	138.956	0.55029235	0.48387090	0.24891837	0.18714848	0.00000000	0.23073438	0.148826873	0.82866608	0.00484372	0.87387878	0.06798815	
185421	52	0.237	0.188	9	-12.982	0.0489	0.812	0.0243	0.0973	0.089	78.779	0.22021404	0.38708774	0.18817426	0.11721418	0.8181818	0.00000000	0.31363488	0.94889885	0.48807144	0.37888887	0.90900000	
211674	51	0.425	0.258	6	-9.324	0.036	0.736	0	0.0734	0.316	152.781	0.39189038	0.35485710	0.38714286	0.23562486	0.47035048	0.13436885	0.78892631	0.00000000	0.84147654	0.37770967	0.81374047	
198073	52	0.563	0.463	8	-7.366	0.0551	0.804	0.0000027	0.092	0.394	96.039	0.25973641	0.38708774	0.67148809	0.58838248	0.72772727	0.66789061	0.88113691	0.85224832	0.00003708	0.86826089	0.47848472	
303847	60	0.387	0.416	9	-10.1	0.0321	0.862	0.0000888	0.118	0.296	156.175	1.00000000	0.64511290	0.30838285	0.44341727	0.8181818	0.38038386	0.80387828	0.91482584	0.00014708	0.18578785	0.24878245	
213732	59	0.639	0.666	0	-7.775	0.0636	0.271	0	0.111	0.372	98.384	0.33767284	0.61292328	0.82248880	0.77288136	0.00000000	0.62656130	0.480966072	0.28843502	0.00000000	0.86622120	0.43229834	
176200	49	0.545	0.349	2	-9.031	0.0478	0.681	0.0000602	0.0885	0.547	79.188	0.10975565	0.29022581	0.630612245	0.25534781	0.18181812	0.469136749	0.266621795	0.34975705	0.00100000	0.07720088	0.38529673	
201453	49	0.726	0.867	10	-4.072	0.0471	0.482	0	0.0446	0.255	87.886	0.27595838	0.29022581	0.60000000	0.7371396	0.80909089	1.00000002	0.30811751	0.51882649	0.00070000	0.00000000	0.18813389	
224893	50	0.444	0.9749	11	-13.848	0.0464	0.84	0.000184	0.106	0.154	87.348	0.28101363	0.32288645	0.42488788	0.80000000	0.697411896	0.38873295	0.898152970	0.000774255	0.888271618	0.80834613	0.15892574	
222113	49	0.602	0.119	5	-8.194	0.0536	0.8771	0	0.0887	0.228	107.428	0.37838892	0.29022581	0.74883878	0.71054289	0.48454545	0.55408819	0.12978986	0.88122882	0.88700000	0.82888125	0.25482722	
207060	52	0.362	0.163	9	-9.869	0.038	0.71	0.000270	0.101	0.354	179.443	0.309889784	0.38708774	0.25714286	0.81887758	0.41454485	0.607781384	0.16794888	0.81336631	0.00468314	0.8133188	0.40424881	
142848	49	0.596	0.709	11	-5.34	0.0547	0.512	0	0.165	0.451	93.297	0.60000000	0.29022581	0.71438574	0.82898867	0.00000500	0.80721098	0.37598882	0.91813874	0.00000000	0.56187813	0.10510816	
274626	47	0.568	0.396	5	-7.598	0.029	0.88	0	0.0859	0.183	128.705	0.60789349	0.22588452	0.63714287	0.81881818	0.45445445	0.84812223	0.15425298	0.72748878	0.00000000	0.788672015	0.11282870	
305593	51	0.444	0.729	9	-4.882	0.0381	0.8088	0.000018	0.0703	0.388	95.258	0.76048697	0.35485710	0.42488788	0.80000000	0.88382500	0.181818187	0.86328361	0.83230874	0.00003890	0.46688838	0.22769863	
230108	47	0.542	0.584	9	-6.784	0.0587	0.883	0.0000304	0.287	0.247	95.648	0.41188482	0.22588452	0.63848978	0.664517127	0.81181818	0.82898867	0.47948579	0.86154870	0.863787052	0.23932248	0.198262818	
183273	48	0.444	0.588	8	-6.684	0.039	0.38	0.0000149	0.102	0.244	119.23	0.24898780	0.24898780	0.42488788	0.33881881	0.77772727	0.87848488	0.71728613	0.29818888	0.00000761	0.32932316	0.45618177	
222293	47	0.543	0.327	9	-8.813	0.0369	0.765	0	0.0889	0.249	135.257	0.37863243	0.22588452	0.62863032	0.32644420	0.81818181	0.72387806	0.144703842	0.83304089	0.00000000	0.86362614	0.23852187	
225720	46	0.457	0.366	2	-7.378	0.0413	0.792	0.0000307	0.0881	0.263	141.36	0.37112736	0.10348387	0.45105048	0.377713489	0.81818182	0.666599435	0.207842377	0.84848408	0.00000067	0.862844889	0.28091853	
231893	45	0.423	0.475	11	-9.849	0.0389	0.455	0	0.144	0.389	167.647	0.42434814	0.16129033	0.37891837	0.81111643	1.00000000	0.81878864	0.449584832	0.483187738	0.00000000	0.143145181	0.30251188	
174833	49	0.579	0.621	0	-5.834	0.0353	0.27	0	0.0965	0.611	138.39	0.15929324	0.29022581	0.70000000	0.71319563	0.45454545	0.812222670	0.12532987	0.28537468	0.00000000	0.81749073	0.01088652	
291533	49	0.417	0.634	9	-7.185	0.0402	0.873	0.0000002	0.113	0.321	152.631	0.70678155	0.29022581	0.38888775	0.73898645	0.81818181	0.686486317	0.29188884	0.818647738	0.00000000	0.88852384	0.353730487	
287346	45	0.538	0.187	5	-11.796	0.0333	0.833	0	0.119	0.396	128.889	0.68892922	0.16129033	0.81887847	0.14271119	0.45454545	0.22000762	0.12532987	0.88488113	0.00000000	0.18714287	0.46984849	
182186	45	0.557	0.185	8	-12.174	0.0483	0.913	0.0000222	0.115	0.418	145.772	0.18748811	0.16129033	0.65010241	0.13588886	0.72772727	0.14293668	0.28643409	0.98816819	0.00036771	0.51178374	0.50887879	
188920	46	0.483	0.596	2	-4.747	0.0521	0.255	0	0.307	0.594	173.82	0.19034400	0.15384837	0.348816227	0.68038223	0.81818182	0.730232965	0.80297828	0.28424980	0.00000000	0.377888101	0.89328887	
156148	42	0.65	0.186	9	-11.04	0.0292	0.882	0	0.114	0.254	114.142	0.90348102	0.09671184	0.84888789	0.14523746	0.81818181	0.29728707	0.15712584	0.838183870	0.00000000	0.88842286	0.34852837	
886953	46	0.424	0.259	9	-13.985	0.0444	0.936	0.0000029	0.739	0.487	69.045	0.68265455	0.15048387	0.38387489	0.23842508	0.81818181	0.04864138	0.242886027	0.93831897	0.000004718	1.00000000	0.81326818	
288268	44	0.887	0.798	3	-5.545	0.0637	0.139	0.000021	0.8986	0.68	118.886	0.30258112	0.12902258	0.82888888	0.86889729	0.72772727	0.881148637	0.88248882	0.14882636	0.000148837	0.828882188	0.828811518	
151333	41	0.555	0.37	10	-9.627	0.0304	0.851	0.000206	0.129	0.533	80.339	0.84847244	0.02288888	0.65102408	0.38297504	0.90909099	0.474862448	0.86201554	0.86227322	0.000421827	0.12542779	0.88284844	
289761	45	0.415	0.599	2	-8.891	0.0318	0.219	0.0000111	0.328	0.553	172.709	0.31502035	0.16129033	0.36036122	0.684292072	0.81818182	0.818589096	0.08010339	0.23113742	0.00001489	0.88122120	0.726848825	
211880	45	0.427	0																				

FORMULA	0	0	0	0.000000000
MAX:	MIN(número1, [número2], ...)			
	0.352954120	0.449161290	0.440161327	0.229025953
	0.595646334	1.000000000	0.124409796	1.000000000
	0.420118609	0.902225006	0.54497959	0.846072385
	0.455022575	0.830709477	0.628571429	0.554006052
	0.485017231	0.704677419	0.677551020	0.793700496
	0.342277945	0.677410355	0.649207755	0.17161669
	0.319594752	0.580645161	0.659183473	0.635574267
	0.650631174	0.580645161	0.000000000	0.656424128
	0.302253547	0.580645161	0.755102041	0.325001804
	0.040155197	0.419354039	0.824001863	0.490356464
	0.331616032	0.540307097	0.640979592	0.514537561
	0.461846520	0.451612903	0.659510367	0.593474542
	0.201994707	0.419354039	0.772469303	0.250091671
	0.554305235	0.403070961	0.240101327	0.167240440
	0.202914504	0.307096774	0.105714206	0.117221401
	0.320199301	0.354030710	0.385714206	0.235424391
	0.257964134	0.307096774	0.667346939	0.505320246
	1.000000000	0.449161290	0.301932245	0.442494277
	0.337702704	0.612903224	0.822440900	0.772395369
	0.164075565	0.290322501	0.630612245	0.355347981
	0.279503630	0.290322501	1.000000000	0.773715985
	0.390101453	0.322510045	0.424409796	0.000000000
	0.371320492	0.290322501	0.746193776	0.710564399
	0.308405794	0.307096774	0.257142187	0.610577556
	0.000000000	0.290322501	0.714205714	0.620649172
	0.607995349	0.228100452	0.657142187	0.419813182
	0.761646597	0.354030710	0.424409796	0.955202200
	0.415064092	0.228100452	0.624409796	0.664517827
	0.240300780	0.251004516	0.424409796	0.630311001
	0.378623473	0.228100452	0.624530612	0.326404420
	0.371102753	0.193540307	0.459102041	0.377713459
	0.422431016	0.161290322	0.376591037	0.521115843
	0.152935234	0.290322501	0.700000000	0.713195632
	0.701578155	0.290322501	0.369387755	0.730296445
	0.681625522	0.161290322	0.615367347	0.142219129
	0.157490591	0.161290322	0.655102041	0.129506496
	0.129046400	0.193540307	0.340613227	0.680305223
	0.063400102	0.096774194	0.04497959	0.143533746
	0.632545905	0.193540307	0.313673469	0.231942501
	0.302253132	0.129032250	0.824001863	0.946059729
	0.040472344	0.032251045	0.651020401	0.302975924
	0.315520355	0.161290322	0.365206122	0.684252072
	0.327647300	0.064516129	0.675510204	0.771002752
	0.795349960	0.161290322	0.171420571	0.472407137
	0.272575546	0.096774194	0.455910367	0.556437205
	0.963492449	0.129032250	0.310204002	0.652477279
	0.077323971	0.000000000	0.635714206	0.147400595
	0.970025751	0.161290322	0.106122449	0.153000315
	0.496495420	0.064516129	0.24693776	0.340323550
	0.304019971	0.064516129	0.914205714	0.601363241
	0.635253304	0.000000000	0.463265306	0.222470728

Alineando en esas filas, la columna a la que corresponde la selección del rango de Mínimo o Máximo.

La formula de Excel es “MIN()” y “MAX()” donde en medio se escribe el rango, en este caso, la columna a la que le estamos sacando el mínimo o el máximo.

Después, lo que sigue es calcular la distancia de todos los puntos hacia el centro correspondiente, que en este caso es el Mínimo y luego el punto Máximo

$$\sqrt{\sum_{i=1}^p (Y_{i1} - Y_{i2})^2}$$

Para el caso del cálculo de la distancia de los objetos de la primera fila a su centro (Minimo), esta fue la formula utilizada para el cálculo. Y se repitió cambiando las respectivas filas en cada fila hasta tener la nueva tabla de la derecha.

[illegible]

Y obtenemos para cada fila, una nueva fila en una tabla nueva de 2 columnas: La distancia de Minino para esa fila, la distancia de máximo para esa fila. Que es la escrita a continuación:

DC0	DC1	Distancia a grupo más cercano	C0	C1
1.645418546	2.397252086	1.645418546	1	0
2.260886111	1.958213892	1.958213892	0	1
2.259361211	1.897547601	1.897547601	0	1
1.737292491	2.443812722	1.737292491	1	0
2.042052171	2.209134944	2.042052171	1	0
1.532076948	2.350248922	1.532076948	1	0
1.908418579	2.112590783	1.908418579	1	0
1.608706290	2.400436277	1.608706290	1	0
1.788463159	2.259151545	1.788463159	1	0
1.877280664	2.151982956	1.877280664	1	0
1.790573988	2.088210542	1.790573988	1	0
1.612464719	2.304836950	1.612464719	1	0
1.312590181	2.481724852	1.312590181	1	0
1.335320655	2.610204696	1.335320655	1	0
1.456141635	2.652157877	1.456141635	1	0
1.537010860	2.346476358	1.537010860	1	0
1.747765462	2.139907290	1.747765462	1	0
2.005265814	2.141225252	2.005265814	1	0
1.655893587	2.295994232	1.655893587	1	0
1.161636362	2.561246315	1.161636362	1	0
1.998353936	2.282479453	1.998353936	1	0
1.531325350	2.654578978	1.531325350	1	0
1.420210550	2.463465831	1.420210550	1	0
1.703334040	2.226615218	1.703334040	1	0
1.918357380	2.238087456	1.918357380	1	0
1.604320742	2.321183611	1.604320742	1	0
1.633074374	2.500271164	1.633074374	1	0
1.681098069	2.148902161	1.681098069	1	0
1.516882630	2.371473493	1.516882630	1	0
1.729967227	2.254963057	1.729967227	1	0
1.487459330	2.395465067	1.487459330	1	0
1.837651991	2.219203429	1.837651991	1	0
1.765495908	2.245614503	1.765495908	1	0
1.773179318	2.227877478	1.773179318	1	0
1.551605452	2.394591207	1.551605452	1	0
1.671295466	2.370685841	1.671295466	1	0
1.686573740	2.345853774	1.686573740	1	0
1.623907629	2.531599564	1.623907629	1	0
1.951322516	2.320507968	1.951322516	1	0
1.990954937	2.234957377	1.990954937	1	0
1.702884444	2.503334198	1.702884444	1	0
1.728890227	2.291480008	1.728890227	1	0
1.955484504	2.366993870	1.955484504	1	0
1.976693639	2.224285584	1.976693639	1	0

1.832393826	2.235078477	1.832393826	1	0
1.509802008	2.518553099	1.509802008	1	0
1.859973777	2.378887209	1.859973777	1	0
1.591369335	2.574126330	1.591369335	1	0
1.548183068	2.361788145	1.548183068	1	0
1.820286698	2.266140598	1.820286698	1	0
1.717230817	2.395832940	1.717230817	1	0
		86.92969653	49	2

Esas 3 columnas auxiliares se obtienen sacando el dato mínimo entre los dos de la izquierda y luego con un filtro condicional eligiendo si pertenecen al Cluster C0 o al C1, respectivamente con:

=MIN(AC6:AD6) Para elegir en la fila A, la menor distancia
=SI(AE6=AC6,1,0) Para elegir en la fila A, si es 1 o 0 en el cluster C0
=SI(AE6=AD6,1,0) Para elegir en la fila A, si es 1 o 0 en el cluster C1

Sólo para colorear los resultados y tener un resultado más fácil de interpretar, pusimos también reglas de formato en Excel.

Regla (aplicada en el orden mostrado)	Formato	Se aplica a	Detener si es verdad
Valor de celda = 0	AaBbCcYyZz	=AF\$6:\$AG\$56,\$AG\$57 	☐
Valor de celda = 1	AaBbCcYyZz	=AF\$6:\$AG\$56,\$AG\$57 	☐

Lo que sigue ahora es crear el promedio de todos los datos de cada columna que correspondan al Cluster C0 o C1 respectivamente. Para considerar únicamente los del Cluster correspondiente ignoraremos todos los que contienen “0”. Y para ignorar esos, vamos a multiplicarlos por su contenido (Es decir, multiplicarlos por 0), podemos multiplicar la columna entera por la columna de “1”s y “0”s confiando en que la multiplicación por 0, eliminará los datos con los que no trabajaremos, pero la multiplicación por “1” no afectará los datos.

Para que no afecten el promedio en la suma. A sí mismo, a la hora de dividir, sólo vamos a contar los que fueron “1”, eso se puede hacer con una cuenta condicional de Excel que cuente solo los datos que son “1”, pero hemos tomado la alternativa de simplemente sumar. Dado a que cada dato es “1”, sumar los “1” es igual a contar los “1”.

=SUMA(AF6:AF56)

Y haciendo lo mismo respectivamente para la fila del Clúster C1. Multiplicar cada columna de datos de la tabla original por los “1” y “0” de la columna auxiliar de pertenencia al Cluster C1 para ignorar los que no son de ahí y promediar para obtener el nuevo centro.

$$=(\text{SUMAPRODUCTO}(\text{P6:P56}, \$\text{AF}\$6:\$ \text{AF}\$56)+\text{AE2})/(\$ \text{AF}\$57+1)$$

Por ejemplo, para obtener de la primera columna y fila (Durabilidad) el promedio de todos los datos que pertenecen al Cluster C0 (Los que son 1)

$$=(\text{SUMAPRODUCTO}(\text{P6:P56}, \$\text{AG}\$6:\$ \text{AG}\$56)+\text{P3})/(\$ \text{AG}\$57+1)$$

Para obtener la primer columna y segunda fila (Durabilidad) el promedio de todos los datos que pertenecen al Cluster C1 (Los que son 1)

Nuevos centroides	Dato	Duration (ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumental	Liveness	Valence	Tempo
	Min	0.400779454	0.311922581	0.537727347	0.47605726	0.60829091	0.576098386	0.196804651	0.567842846	0.050133813	0.133457834	0.39813777	0.441748292
	Max	0.673220648	0.967741935	0.556462585	0.94869096	0.81818182	0.868932365	0.921619294	0.546268233	0.333528239	0.377400154	0.57713433	0.874324532

Y ahora que tenemos nuevos centros, podemos repetir el proceso tantas veces sea necesario hasta obtener como la suma de las distancias de los centros a cada fila, un resultado que comparado a la iteración anterior no sea significativamente distinto.

Es decir, con ese nuevo encabezado de datos asociados a los 2 centros: Min y Max (C0 y C1), calcular en cada fila la distancia euclidiana de todos los datos en esas columnas al centro, verde para el centro de C0 y rojo para el centro de C1.

Y una vez teniendo esas nuevas columnas con las distancias euclidianas, nuevamente, calcular para cada fila, entre esas dos columnas cuál de ellas tiene la menor distancia. Y elegir con una función MIN() la que tenga la menor distancia y luego comprar esa distancia con ambas para escribir a cuál de ellas corresponde dicha distancia. Para así asegurar seleccionar en cada fila, en una nueva columna, a qué Cluster pertenece cada fila de datos, tomando como nuevo centro, el calculado previamente.

Y volver a obtener también un promedio de todos los datos ubicados en cada Cluster para obtener nuevamente un centro de Cluster distinto al anterior. En donde se espera que sea distinto porque en teoría se consideran distintos datos asociados a cada Cluster ahora que se aproximaron más las distancias a un “Centro ideal”.

En el momento en que esa cantidad de datos asociados al Cluster C0 o C1, ya no cambia, entonces se sabe que la distancia del siguiente centroide calculado tampoco cambiará, porque será un promedio de los mismos datos. En nuestro caso, esto ocurrió tras tres iteraciones:

DC0	DC1	Distancia a grupo más cercano	C0	C1
1.645418546	2.397252086	1.645418546	1	0
2.26086111	1.958213892	1.958213892	0	1
2.259361211	1.897547601	1.897547601	0	1
1.737292491	2.443812722	1.737292491	1	0
2.042052171	2.209134944	2.042052171	1	0
1.532076948	2.350248922	1.532076948	1	0
1.908418579	2.112590783	1.908418579	1	0
1.608708290	2.400436277	1.608708290	1	0
1.788463159	2.259151545	1.788463159	1	0
1.877280664	2.151982956	1.877280664	1	0
1.790573988	2.088210542	1.790573988	1	0
1.612464719	2.304836950	1.612464719	1	0
1.312590181	2.481724852	1.312590181	1	0
1.335320655	2.610204696	1.335320655	1	0
1.456141635	2.652157877	1.456141635	1	0
1.537010860	2.346476358	1.537010860	1	0
1.747765462	2.139907290	1.747765462	1	0
2.005265814	2.141225252	2.005265814	1	0
1.655893587	2.295994232	1.655893587	1	0
1.161636362	2.561246312	1.161636362	1	0
1.998353936	2.282479453	1.998353936	1	0
1.531325350	2.654578978	1.531325350	1	0
1.420210550	2.463456531	1.420210550	1	0
1.763334040	2.226615218	1.763334040	1	0
1.918357390	2.238087456	1.918357390	1	0
1.604320742	2.321183611	1.604320742	1	0
1.633074374	2.500271164	1.633074374	1	0
1.681098069	2.148902161	1.681098069	1	0
1.516882630	2.371473493	1.516882630	1	0
1.729967227	2.254963057	1.729967227	1	0
1.487459330	2.395465067	1.487459330	1	0
1.837651991	2.219203429	1.837651991	1	0
1.765495908	2.245614503	1.765495908	1	0
1.773179318	2.227877478	1.773179318	1	0
1.551605452	2.394591207	1.551605452	1	0
1.671295466	2.370685841	1.671295466	1	0
1.686573740	2.345853774	1.686573740	1	0
1.623907629	2.531599564	1.623907629	1	0
1.951322516	2.320507968	1.951322516	1	0
1.989054937	2.234957377	1.989054937	1	0
1.702884444	2.503334198	1.702884444	1	0
1.728890227	2.291480008	1.728890227	1	0
1.955484504	2.366983870	1.955484504	1	0
1.976693639	2.224285584	1.976693639	1	0
1.832393826	2.235078477	1.832393826	1	0
1.509802008	2.518553099	1.509802008	1	0
1.859973777	2.378887209	1.859973777	1	0
1.591369335	2.574126330	1.591369335	1	0
1.548183068	2.361788145	1.548183068	1	0
1.820286698	2.266140598	1.820286698	1	0
1.717230817	2.395832940	1.717230817	1	0

86.92969653 49 2

DC0	DC1	Distancia a grupo n	C0	C1
0.843350900	1.628720684	0.843350900	1	0
1.254209136	0.751603809	0.751603809	0	1
1.243047833	0.697808500	0.697808500	0	1
0.949784090	1.510261887	0.949784090	1	0
1.159129256	1.392092428	1.159129256	1	0
0.658548830	1.573723088	0.658548830	1	0
0.727174926	1.216730461	0.727174926	1	0
0.882375279	1.447024794	0.882375279	1	0
0.696951778	1.568330857	0.696951778	1	0
1.079328657	1.670193669	1.079328657	1	0
0.525535338	1.235157777	0.525535338	1	0
0.493553365	1.452348093	0.493553365	1	0
0.495214764	1.577172681	0.495214764	1	0
0.931187044	1.783040958	0.931187044	1	0
1.118425070	1.941721358	1.118425070	1	0
0.550749050	1.491842376	0.550749050	1	0
0.492635194	1.326375855	0.492635194	1	0
0.937483942	1.377924354	0.937483942	1	0
0.914748725	1.384198401	0.914748725	1	0
0.636298355	1.715592764	0.636298355	1	0
0.881915725	1.478474854	0.881915725	1	0
0.992012610	1.915188435	0.992012610	1	0
0.641197119	1.529515100	0.641197119	1	0
0.657828711	1.281879003	0.657828711	1	0
0.876343150	1.391962751	0.876343150	1	0
0.501455488	1.512571218	0.501455488	1	0
0.975262034	1.599197333	0.975262034	1	0
0.587709330	1.293777100	0.587709330	1	0
0.501721090	1.396826415	0.501721090	1	0
0.489241041	1.466407476	0.489241041	1	0
0.592756366	1.564465884	0.592756366	1	0
0.683370058	1.345693477	0.683370058	1	0
0.726432687	1.404770051	0.726432687	1	0
0.806398921	1.230368339	0.806398921	1	0
0.692943859	1.713895425	0.692943859	1	0
0.769641180	1.698324066	0.769641180	1	0
0.944191961	1.540653513	0.944191961	1	0
0.805301221	1.851402226	0.805301221	1	0
1.298113203	1.938931320	1.298113203	1	0
1.079173063	1.464252920	1.079173063	1	0
0.826694657	1.863157249	0.826694657	1	0
0.929341444	1.494856763	0.929341444	1	0
0.985598394	1.636767522	0.985598394	1	0
1.209685369	1.422380535	1.209685369	1	0
0.836209695	1.357574971	0.836209695	1	0
0.831316937	1.670603917	0.831316937	1	0
0.909059193	1.798151695	0.909059193	1	0
1.001515848	1.870345901	1.001515848	1	0
0.488236160	1.530839189	0.488236160	1	0
1.222989342	1.744389146	1.222989342	1	0
0.768780295	1.669611602	0.768780295	1	0

41.054823621 49 2

DC0	DC1	Distancia Min	C0	C1
0.845379118	1.628720684	0.845379118	1	0
1.243228696	0.751603809	0.751603809	0	1
1.231797611	0.697808500	0.697808500	0	1
0.950324288	1.510261887	0.950324288	1	0
1.153430122	1.392092428	1.153430122	1	0
0.662392209	1.573723088	0.662392209	1	0
0.714849126	1.216730461	0.714849126	1	0
0.886423984	1.447024794	0.886423984	1	0
0.68981235	1.568330857	0.68981235	1	0
1.077550020	1.670193669	1.077550020	1	0
0.510819529	1.235157777	0.510819529	1	0
0.489708399	1.452348093	0.489708399	1	0
0.508952747	1.577172681	0.508952747	1	0
0.944530685	1.783040958	0.944530685	1	0
1.129970576	1.941721358	1.129970576	1	0
0.552712675	1.491842376	0.552712675	1	0
0.479372384	1.326375855	0.479372384	1	0
0.927027608	1.377924354	0.927027608	1	0
0.917610596	1.384198401	0.917610596	1	0
0.655235431	1.715592764	0.655235431	1	0
0.869848749	1.478474854	0.869848749	1	0
1.000110194	1.915188435	1.000110194	1	0
0.649895993	1.529515100	0.649895993	1	0
0.853336818	1.281879003	0.853336818	1	0
0.867803725	1.391962751	0.867803725	1	0
0.498355496	1.512571218	0.498355496	1	0
0.979881860	1.599197333	0.979881860	1	0
0.582354557	1.293777100	0.582354557	1	0
0.504071639	1.396826415	0.504071639	1	0
0.477112714	1.466407476	0.477112714	1	0
0.597900450	1.564465884	0.597900450	1	0
0.672416221	1.345693477	0.672416221	1	0
0.720602084	1.404770051	0.720602084	1	0
0.802340232	1.230368339	0.802340232	1	0
0.696400293	1.713895425	0.696400293	1	0
0.769410373	1.698324066	0.769410373	1	0
0.946459799	1.540653513	0.946459799	1	0
0.807519090	1.851402226	0.807519090	1	0
1.298458700	1.938931320	1.298458700	1	0
1.073301962	1.464252920	1.073301962	1	0
0.826102034	1.863157249	0.826102034	1	0
0.929793603	1.494856763	0.929793603	1	0
0.978622617	1.636767522	0.978622617	1	0
1.207601565	1.422380535	1.207601565	1	0
0.830317160	1.357574971	0.830317160	1	0
0.838252890	1.670603917	0.838252890	1	0
0.903921834	1.798151695	0.903921834	1	0
1.007866007	1.870345901	1.007866007	1	0
0.488418841	1.530839189	0.488418841	1	0
1.225845202	1.744389146	1.225845202	1	0
0.766299102	1.669611602	0.766299102	1	0

41.014704846 0

MIN:	0	0	0	0.000000000	0	0	0	0	0	0	0	0	0
MAX:	1	1	1	1	1	1	1	1	1	1	1	1	1

Nuevos centroides	Dato	Duration (ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumentalness	Liveness	Valence	Tempo	
	Min		0.392921033	0.305806452	0.527183673	0.4667228	0.596363636	0.56480234	0.192945736	0.556708672	0.049150797	0.130841014	0.390331147	0.433086561
	Max		0.673220648	0.967741935	0.556462585	0.948690962	0.818181818	0.868932365	0.921619294	0.546268233	0.333528239	0.377400154	0.577134325	0.874324532

Nuevos centroides	Dato	Duration (ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumentalness	Liveness	Valence	Tempo
	Min	0.400779454	0.311922581	0.537727347	0.47605726	0.60829091	0.576098396	0.196804651	0.567842846	0.050133813	0.133457834	0.39813777	0.441748292
	Max	0.673220648	0.967741935	0.556462585	0.94869096	0.81818182	0.868932365	0.921619294	0.546268233	0.333528239	0.377400154	0.57713433	0.874324532

Nuevos centroides	Dato	Duration (ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumentalness	Liveness	Valence	Tempo
	Min	0.400936622	0.3120449	0.53793822	0.476243945	0.608529455	0.576324307	0.196881829	0.568065529	0.05015347	0.13351017	0.3982939	0.44192153
	Max	1.509660714	0.32258065	0.8521542	0.316230321	0.272727273	0.289644122	0.307206431	0.182089411	0.11117608	0.12580005	0.19237811	0.29144151

Finalmente, en cuanto se detengan las iteraciones, es momento de comenzar con medoides, en donde tomaremos como datos asociados a mínimos y máximos los valores que no consideran separado el centroide de la colección de datos.

Siendo nuestra tabla inicial esta:

0.378623473	0.225806452	0.626530612	0.32640442	0.818181818	0.723578056	0.144702842	0.833040889	0	0.063652074	0.238521837	0.574921636
0.420115608	0.903225806	0.544897959	0.846072885	0.818181818	0.644715611	1	0.216249269	0.000584718	0.057459677	0.406494961	0.894014779
Duration (ms)	Popularity	Danceability	Energy	Key	Loudness	Speechiness	Acousticness	Instrumentalness	Liveness	Valence	Tempo
0.583596620	0.645161290	0.440816327	0.329035653	0.727272727	0.161960468	0.218346253	1.000000000	0.021262458	0.076756912	0.156934890	0.119148714
0.599546336	1.000000000	0.124489796	1.000000000	0.636363636	0.962081484	0.764857881	0.422555431	0.000000000	0.074740783	0.324908015	0.728958816
0.420115608	0.903225806	0.544897959	0.846072885	0.818181818	0.644715611	1.000000000	0.216249269	0.000584718	0.057459677	0.406494961	0.894014779
0.455822575	0.838709677	0.628571429	0.554006052	1.000000000	0.578358209	0.005167959	0.032806934	0.000062791	0.092741935	0.123340266	0.213394462
0.415817238	0.709677419	0.677551020	0.798710696	0.090909091	0.741528842	0.095607235	0.157760408	0.000030066	0.062644009	1.000000000	0.894613908
0.342277945	0.677419355	0.669387755	0.171161689	0.272727273	0.510891489	0.078811370	0.768171426	0.000662791	0.089861751	0.483282675	0.347139372
0.319594752	0.580645161	0.659183673	0.635574267	1.000000000	0.838442921	0.089147287	0.214122401	0.000157475	0.180587558	0.524876020	0.547179314
0.650631174	0.580645161	0.000000000	0.656624128	0.636363636	0.858309802	0.191214470	0.345988196	0.002491694	0.232430876	0.203327468	0.054894197
0.302253547	0.580645161	0.755102041	0.325088804	0.909090909	0.399052037	0.049095607	0.892593183	0.000000000	0.135944700	0.502479603	0.196071791
0.048158897	0.419354839	0.820408163	0.490856466	0.818181818	0.440903590	0.052971576	0.644813102	0.958471761	0.097062212	0.385698288	0.269695312
0.331660832	0.548387097	0.648897592	0.514537561	0.727272727	0.744655103	0.377260982	0.817089382	0.000043189	0.088421659	0.393697008	0.230560838
0.468465120	0.451612903	0.695918367	0.593474543	0.636363636	0.730032271	0.072351421	0.576753337	0.000054651	0.084101382	0.192129259	0.142627662
0.201994787	0.419354839	0.373469388	0.250098671	0.636363636	0.463896733	0.129198966	0.663954910	0.000303987	0.102822581	0.083346665	0.457162208
0.556205235	0.483870968	0.240816327	0.167214840	0.000000000	0.220754336	0.140826873	0.826660286	0.003488372	0.073876728	0.163333867	0.607908515
0.202914504	0.387096774	0.185714286	0.117221418	0.818181818	0.000000000	0.313953488	0.968096985	0.406976744	0.075892857	0.000000000	0.067154654
0.328019938	0.354838710	0.385714286	0.235626891	0.545454545	0.470350948	0.134366925	0.780932631	0.000000000	0.041474654	0.337705967	0.813740047
0.257964136	0.387096774	0.667346939	0.505328246	0.727272727	0.667809601	0.381136951	0.853246132	0.000037708	0.068260369	0.470484722	0.251756145
1.000000000	0.645161290	0.308163265	0.443494277	0.818181818	0.392093586	0.083979328	0.914925294	0.000147508	0.105702765	0.249720045	0.756553527
0.337827084	0.612903226	0.822448980	0.772398369	0.000000000	0.626563130	0.490956072	0.286435902	0.000000000	0.095622120	0.435290354	0.254751795
0.169075565	0.290322581	0.630612245	0.355347981	0.181818182	0.409136749	0.286821705	0.509757005	0.001000000	0.077620968	0.395296753	0.087898443
0.279503638	0.290322581	1.000000000	0.773713985	0.909090909	1.000000000	0.303617571	0.510820439	0.000000000	0.000000000	0.168133099	0.156650777
0.391013453	0.322580645	0.424489796	0.000000000	1.000000000	0.014118596	0.268733850	0.891529750	0.002724252	0.088421659	0.086546153	0.158925734
0.376336092	0.290322581	0.746938776	0.710564399	0.454545455	0.584308189	0.129198966	0.080236082	0.000000000	0.063508065	0.204927212	0.333281235
0.308605794	0.387096774	0.257142857	0.610577556	0.454545455	0.697761194	0.167958656	0.636305631	0.005465116	0.081221198	0.406494961	0.958590568
0.000000000	0.290322581	0.714285714	0.828969872	1.000000000	0.882210569	0.375968992	0.298133674	0.000000000	0.173387097	0.561670133	0.210581156
0.607995349	0.225806452	0.657142857	0.419813182	0.454545455	0.644312223	0.054263566	0.722443771	0.000000000	0.059475806	0.132938730	0.614238454
0.766048597	0.354838710	0.424489796	0.855282200	0.181818182	0.861839451	0.032299742	0.005636199	0.000029900	0.037010369	0.460886258	0.227608603
0.415864892	0.225806452	0.624489796	0.664517827	0.818181818	0.726502622	0.427648579	0.405540490	0.000538206	0.363479263	0.235322348	0.196262818
0.240808780	0.258064516	0.424489796	0.630311801	0.727272727	0.837434449	0.173126615	0.298133674	0.000024751	0.082661290	0.230523116	0.435671677
0.378623473	0.225806452	0.626530612	0.326404420	0.818181818	0.723578056	0.144702842	0.833040889	0.000000000	0.063652074	0.238521837	0.574921636
0.371127536	0.193548387	0.451020408	0.377713459	0.181818182	0.666599435	0.202842377	0.840484926	0.000509967	0.062644009	0.260918253	0.627914246
0.423418014	0.161290323	0.379591837	0.521115643	1.000000000	0.810709964	0.145994832	0.482107726	0.000000000	0.143145161	0.302511598	0.856165395
0.152935234	0.290322581	0.700000000	0.713195632	0.454545455	0.812222670	0.125322997	0.285372468	0.000000000	0.074740783	0.817629179	0.610808652
0.708578155	0.290322581	0.369387755	0.730298645	0.818181818	0.686466317	0.291989664	0.016642739	0.000335548	0.098502304	0.353703407	0.725954483
0.688625522	0.161290323	0.618367347	0.142218129	0.454545455	0.225090762	0.125322997	0.884085713	0.000000000	0.107142857	0.409694449	0.520322662
0.187498511	0.161290323	0.655102041	0.139586896	0.727272727	0.182936668	0.236434109	0.969160419	0.000368771	0.151785714	0.508878579	0.666223831
0.129046400	0.193548387	0.340816327	0.680305223	0.181818182	0.730233965	0.083979328	0.269420960	0.000000000	0.377880184	0.790433531	0.893268037
0.063408102	0.096774194	0.844897959	0.143533746	0.818181818	0.297297297	0.175710594	0.936193970	0.000000000	0.099942396	0.246520557	0.391579185
0.682654505	0.193548387	0.383673469	0.236942508	0.818181818	0.040641388	0.242894057	0.993619397	0.000034718	1.000000000	0.619260918	0.000000000
0.302258312	0.129032258	0.920408163	0.946059729	0.272727273	0.851149657	0.492248062	0.146062636	0.000348837	0.065092166	0.928011518	0.431034932
0.040472344	0.032258065	0.651020408	0.382975924	0.909090909	0.419624849	0.062015504	0.903227522	0.003421927	0.121543779	0.692849144	0.098066286
0.315520355	0.161290323	0.365306122	0.684252072	0.181818182	0.816559096	0.080103359	0.231137342	0.000018439	0.408122120	0.724844025	0.900118958
0.327667300	0.064516129	0.675510204	0.771082752	1.000000000	0.960367084	0.000000000	0.074174509	0.000000000	0.190668203	0.796832507	0.249811144
0.795369960	0.161290323	0.171428571	0.472437837	0.000000000	0.648951190	0.819121447	0.745839315	0.000209302	0.081221198	0.584066549	1.000000000
0.272579546	0.096774194	0.495918367	0.556637285	0.545454545	0.889874950	0.339793282	0.235391078	0.000000000	0.050835253	0.764837626	0.932949543
0.963492449	0.129032258	0.310204082	0.652677279	0.454545455	0.677289230	0.047803618	0.281118732	0.037375415	0.073444700	0.188929771	0.152283206
0.077832897	0.000000000	0.685714286	0.147480595	1.000000000	0.347216620	0.160206718	0.997873132	0.001038206	0.254032258	0.614461686	0.614342650
0.970025781	0.161290323	0.106122449	0.133008815	0.636363636	0.302642194	0.189922481	0.960652948	0.000000000	0.164746544	0.163333867	0.165055962
0.496995430	0.064516129	0.346938776	0.344823050	0.636363636	0.629386850	0.120155039	0.722443771	0.009435216	0.049395161	0.297712366	0.691248361
0.304011971	0.064516129	0.914285714	0.601368241	0.454545455	0.640681727	0.188630491	0.000000000	1.000000000	0.088421659	0.494480883	0.338082958
0.635253304	0.000000000	0.463265306	0.222470728	0.909090909	0.377369907	0.248062016	0.924496198	0.000470100	0.084101382	0.129739242	0.610114008

Pero las formulas siguen siendo las mismas, solo que sin separar ni del cociente de la división en el promedio, ni de la suma de términos en el propio promedio, el dato del centro. Como se muestra a continuación.

[illegible]

1.6377984	1.3181415	1.0737894	1	0	1	6.02661493	1.2465744	0.62661493	1	0	1	0.59465653	1.22761496	0.59465653	1	0	1	0.58812308	1.21558044	0.58812308	1	0	1
1.13375671	1.03967465	1.03967465	1	0	1	1.37521325	1.03694421	1.03694421	0	1	1	1.44701772	1.03119447	1.03119447	0	1	1	1.46202414	1.03362604	1.03362604	0	1	1
1.32798474	1.024855	1.024855	1	0	1	1.37099966	1.01534156	1.01534156	0	1	1	1.42764618	1.03347589	1.03347589	0	1	1	1.44338189	1.03402411	1.03402411	0	1	1
0.95878552	1.10673806	0.95878552	1	0	1	1.01184452	0.99956498	0.99956498	0	1	1	1.10348328	0.92938472	0.92938472	0	1	1	1.12050419	0.9208125	0.9208125	0	1	1
1.347396	0.75205776	0.75205776	0	1	1	1.39148586	0.81848521	0.81848521	0	1	1	1.43521931	0.88921936	0.88921936	0	1	1	1.44264664	0.91072382	0.91072382	0	1	1
0.65691222	0.95977702	0.65697122	1	0	1	0.64414705	0.92452318	0.64414705	1	0	1	0.62351498	0.9442152	0.62351498	1	0	1	0.61707397	0.94291375	0.61707397	1	0	1
0.81273758	0.70362184	0.70362184	0	1	1	0.88369712	0.61769226	0.61769226	0	1	1	0.97842525	0.56618264	0.56618264	0	1	1	0.995617	0.5618273	0.5618273	0	1	1
0.92322968	1.00093276	0.92322968	1	0	1	0.95598127	0.93223522	0.93223522	0	1	1	1.07476999	0.86301884	0.86301884	0	1	1	1.06576869	0.85335162	0.85335162	0	1	1
0.56929044	1.4508446	0.56929044	1	0	1	0.55154499	0.95881593	0.55154499	0	1	1	0.53730309	1.04547803	0.53730309	0	1	1	0.53748451	1.03474651	0.53748451	0	1	1
1.06104218	1.31422025	1.06104218	1	0	1	1.07801002	1.2550591	1.07801002	0	1	1	1.08052073	1.25148976	1.08052073	1	0	1	1.08485489	1.24452065	1.08485489	1	0	1
0.7420133	0.83934386	0.7420133	1	0	1	0.5021664	0.96271385	0.5021664	1	0	1	0.55149374	0.74325134	0.55149374	1	0	1	0.56873219	0.72921838	0.56873219	1	0	1
0.48133562	0.82724675	0.48133562	1	0	1	0.52808063	0.73080078	0.52808063	1	0	1	0.62184256	0.67136366	0.62184256	1	0	1	0.64174479	0.65641551	0.64174479	1	0	1
0.40423112	0.9517487	0.40423112	1	0	1	0.39907005	0.88339205	0.39907005	1	0	1	0.41628559	0.86154278	0.41628559	1	0	1	0.41872363	0.85248556	0.41872363	1	0	1
0.92994184	1.19287369	0.92994184	1	0	1	0.88689141	1.19308634	0.88689141	0	1	1	0.85028071	1.2146149	0.85028071	1	0	1	0.83609878	1.21606476	0.83609878	1	0	1
0.9684589	1.59631053	0.9684589	1	0	1	0.92321818	1.59686371	0.92321818	1	0	1	0.87107184	1.51195543	0.87107184	1	0	1	0.86292637	1.49965332	0.86292637	1	0	1
0.54313538	0.89500523	0.54313538	1	0	1	0.52441004	0.84296373	0.52441004	1	0	1	0.50576959	0.89622919	0.50576959	1	0	1	0.49588686	0.85943033	0.49588686	1	0	1
0.44733366	0.8375458	0.44733366	1	0	1	0.46549493	0.76681787	0.46549493	0	1	1	0.49195598	0.78081793	0.49195598	0	1	1	0.50865125	0.78884583	0.50865125	1	0	1
0.86776302	1.9562192	0.86776302	1	0	1	0.83919524	1.17100088	0.83919524	1	0	1	0.85668065	1.1523774	0.85668065	0	1	1	0.85246099	1.14933652	0.85246099	1	0	1
1.05720972	0.77259979	0.77259979	0	1	1	1.09525426	0.75427697	0.75427697	0	1	1	1.14305456	0.78915863	0.78915863	1	0	1	1.1581129	0.78956307	0.78956307	1	0	1
0.69823835	0.9042667	0.69823835	1	0	1	0.71228569	0.85220869	0.71228569	1	0	1	0.71308025	0.8680555	0.71308025	1	0	1	0.72131048	0.86072224	0.72131048	1	0	1
0.88453939	1.01913321	0.88453939	1	0	1	0.94665782	0.92999126	0.92999126	1	0	1	1.03016206	0.87179426	0.87179426	1	0	1	1.0532871	0.85517818	0.85517818	1	0	1
0.80476116	1.51542754	0.80476116	1	0	1	0.75485062	1.43939073	0.75485062	1	0	1	0.70213161	1.41651695	0.70213161	0	1	1	0.69427666	1.40240311	0.69427666	1	0	1
0.77947493	0.65931328	0.65931328	0	1	1	0.84530991	0.57733599	0.57733599	0	1	1	0.92960408	0.5336913	0.5336913	0	1	1	0.9494905	0.52664949	0.52664949	0	1	1
0.7172096	1.6109994	0.6109994	1	0	1	0.74967988	0.63749898	0.63749898	0	1	1	0.8322903	0.66650567	0.66650567	0	1	1	0.83682334	0.6752774	0.6752774	0	1	1
0.94967799	0.8787199	0.8787199	1	0	1	1.0215897	0.7875077	0.7875077	0	1	1	1.09890247	0.7531451	0.7531451	0	1	1	1.1291451	0.7383678	0.7383678	0	1	1
0.5057043	0.81173305	0.5057043	1	0	1	0.5046755	0.76666818	0.5046755	0	1	1	0.5479674	0.78420509	0.5479674	1	0	1	0.5552729	0.75872562	0.5552729	1	0	1
1.1408986	0.78118305	0.78118305	0	1	1	1.19046806	0.76639713	0.76639713	0	1	1	1.2790564	0.73006449	0.73006449	0	1	1	1.29603776	0.73546323	0.73546323	0	1	1
0.62122746	0.78516953	0.62122746	1	0	1	0.67986189	0.68997096	0.67986189	1	0	1	0.76920945	0.6289025	0.6289025	0	1	1	0.79887585	0.6046104	0.6046104	0	1	1
0.6113332	0.59840151	0.59840151	0	1	1	0.68392091	0.50680342	0.50680342	1	0	1	0.78707392	0.43015504	0.43015504	0	1	1	0.80939679	0.41789477	0.41789477	0	1	1
0.39020889	0.89375957	0.39020889	1	0	1	0.3954558	0.84123921	0.3954558	1	0	1	0.43432919	0.8139036	0.43432919	1	0	1	0.44722212	0.8032389	0.44722212	1	0	1
0.64510766	0.81142359	0.64510766	1	0	1	0.63387023	0.81851784	0.63387023	1	0	1	0.6308363	0.8382976	0.6308363	1	0	1	0.62960682	0.8372827	0.62960682	1	0	1
0.72447228	0.78456602	0.72447228	0	1	1	0.76992545	0.75042837	0.75042837	0	1	1	0.64066871	0.76830311	0.76830311	0	1	1	0.85499804	0.73030982	0.73030982	0	1	1
0.64443605	0.44474365	0.64443605	0	1	1	0.97716748	0.64736996	0.64736996	1	0	1	1.03296285	0.49836951	0.49836951	0	1	1	1.047053	0.41897044	0.41897044	0	1	1
0.9371896	0.64830698	0.64830698	1	0	1	0.98237216	0.61434906	0.61434906	1	0	1	1.08955175	0.580975	0.580975	0	1	1	1.1089778	0.5696729	0.5696729	0	1	1
0.6298495	1.09404436	0.6298495	1	0	1	0.5738743	1.07522343	0.5738743	1	0	1	0.50959294	1.08624335	0.50959294	0	1	1	0.49495485	1.09063393	0.49495485	1	0	1
0.6863611	1.15976938	0.6863611	1	0	1	0.64939408	1.2980187	0.64939408	1	0	1	0.56001836	1.15587924	0.56001836	1	0	1	0.54600128	1.14918483	0.54600128	1	0	1
1.13535088	0.64842901	0.64842901	0	1	1	1.17645133	0.71258841	0.71258841	0	1	1	1.21069666	0.77520346	0.77520346	0	1	1	1.21988358	0.78845651	0.78845651	0	1	1
0.6705488	1.27391391	0.6705488	1	0	1	0.64623109	1.21179358	0.64623109	1	0	1	0.58398862	1.20958173	0.58398862	1	0	1	0.57888092	1.19718359	0.57888092	1	0	1
1.21203978	1.6590484	1.21203978	1	0	1	1.17851807	1.61148444	1.17851807	1	0	1	1.37859494	1.60677611	1.37859494	1	0	1	1.14110469	1.59166899	1.59166899	1	0	1
1.26450096	0.72418285	0.72418285	1	0	1	1.32193779	0.74880382	0.74880382	1	0	1	1.13795091	0.79687823	0.79687823	0	1	1	1.39405999	0.80142894	0.80142894	1	0	1
0.75439418	1.22176136	0.75439418	1	0	1	0.76967398	1.15247492	0.76967398	1	0	1	0.73065743	1.04862636	0.73065743	1	0	1	0.7340382	1.13655727	0.7340382	1	0	1
1.12580714	0.59071916	0.59071916	1	0	1	1.18772254	0.72298547	0.72298547	0	1	1	1.2135576	0.72298547	0.72298547	0	1	1	1.2248671	0.7583293	0.7583293	0	1	1
1.09632169	0.91794296	0.91794296	1	0	1	1.16746749	0.85490976	0.85490976	1	0	1	1.25040313	0.80665353	0.80665353	0	1	1	1.27178006	0.80029964	0.80029964	1	0	1
1.1325265	1.0725721	1.0725721	0	1	1	1.30574508	1.15367565	1.15367565	1	0	1	1.30684727	1.20654164	1.20654164	1	0	1	1.3000092	1.21225677	1.21225677	0	1	1
1.01652134	0.49907412	0.49907412	0	1	1	1.06733216	0.56351766	0.56351766	1	0	1	1.12060163	0.68397578	0.68397578	1	0	1	1.133381	0.62053805	0.62053805	0	1	1
0.90039841	0.95951019	0.90039841	1	0	1	0.92428989	0.91609071	0.91609071	1	0	1	1.0094362	0.82525222	0.82525222	0	1	1	1.0253401	0.84509298	0.84509298	1	0	1
0.82128872	1.27838619	0.82128872	1	0	1	0.80315504	1.23918909	0.80315504	1	0	1	0.7453797	1.25084202	0.7453797	1	0	1	0.74030604	1.24154578	1.24154578	0	1	1
0.88701036	0.46295299	0.88701036	1	0	1	0.83049013	0.78981534	0.78981534	1	0	1	0.6132196	1.38087523	0.6132196	1	0	1	0.686683	1.34713842	0.686683	1	0	1
0.49540054	1.03979421	0.49540054	1	0	1	0.49137663	0.86561856	0.86561856	0	1	1	0.52258128	1.77098888	0.52258128	0	1	1	0.52599093	0.76				

Estos datos se encontrarán en el archivo adjunto en esta misma carpeta llamado:
Resultados Práctica 5 (Parte 1).xlsx

Finalmente, aquí las iteraciones se detienen en cuanto el número de elementos asociados a cada fila deja de cambiar, es decir, cuando C0 o C1, ya no ganan o pierden elementos. Pues esto nos garantiza que a la siguiente iteración, el centro ya no va a cambiar respecto a los elementos que se promedian para cada grupo. Y el resultado de elementos se volverá a repetir.

En nuestro caso, fueron 7 iteraciones.

Parte 2

Para esta parte se trabajó con el archivo `spotify_latinos_50.csv`, el cual fue generado a partir del dataset original `spotifydataset.csv`. El archivo original contenía 1000 registros y 23 variables. Después de aplicar el filtrado por géneros latinos, se obtuvo un subconjunto de 90 canciones. Posteriormente, se tomó una muestra aleatoria de 50 canciones para realizar el análisis de clustering.




Figura 1. Carga, filtrado y generación del dataset de canciones latinas.

Selección de variables numéricas

Para aplicar los algoritmos de clustering se seleccionaron únicamente variables numéricas, ya que estos métodos trabajan calculando distancias entre registros. Las variables utilizadas fueron `duration_ms`, `track_popularity`, `danceability`, `energy`, `key`, `loudness`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence` y `tempo`.

Estas variables representan características musicales de las canciones, como duración, popularidad, energía, acústica, instrumentalidad, valencia y tempo. Con ellas fue posible comparar las canciones de acuerdo con sus propiedades numéricas y formar grupos con registros similares.




Figura 2. Selección de variables numéricas para el análisis de clustering.

Escalamiento de datos

Después de seleccionar las variables numéricas, se aplicó escalamiento a los datos mediante la función `scale()`. Este paso fue necesario porque las variables tienen diferentes rangos de valores. Por ejemplo, `duration_ms` maneja valores grandes porque representa la duración de la canción en milisegundos, mientras que variables como `danceability`, `energy` y `valence` manejan valores más pequeños.

El escalamiento permitió que todas las variables quedaran en una escala comparable. De esta forma se evitó que una variable con valores más grandes tuviera mayor influencia en el cálculo de distancias utilizado por los algoritmos de clustering.




Figura 3. Escalamiento de variables numéricas mediante la función scale().

Método del codo / WSS

Se utilizó el método del codo para analizar cómo disminuye la suma de cuadrados dentro de los grupos conforme aumenta el número de clústeres. Este método ayuda a identificar el punto donde agregar más grupos ya no mejora de forma significativa el error del agrupamiento.

En la gráfica del método del codo se observa que la suma de cuadrados disminuye conforme aumenta el número de clústeres. Sin embargo, a partir de cierto punto la reducción deja de ser tan pronunciada, lo cual sirve como referencia para seleccionar una cantidad adecuada de grupos.




Figura 4. Método del codo / WSS para analizar el número de clústeres.

Método Silhouette

También se aplicó el método Silhouette, el cual permite evaluar qué tan bien agrupado se encuentra cada registro dentro de su clúster. Un valor más alto indica que los elementos están mejor separados y que los registros dentro de cada grupo son más similares entre sí.

Con este método se comparó la calidad del agrupamiento para distintos valores de k. Esto ayudó a identificar qué cantidad de clústeres podía generar grupos más compactos y mejor definidos.




Figura 5. Método Silhouette para evaluar la calidad del agrupamiento.

Gap Statistic

El tercer método utilizado fue Gap Statistic. Este método compara la estructura de los datos reales contra una distribución aleatoria, con el objetivo de identificar si los grupos encontrados tienen una separación significativa.

Este resultado permitió reforzar la selección del número de clústeres, ya que no se tomó una sola gráfica como criterio absoluto, sino que se compararon varios métodos.




Figura 6. Gap Statistic para analizar la cantidad de clústeres.

En la gráfica de Gap Statistic se observa que el método marca como referencia inicial un valor cercano a $k = 1$. Sin embargo, utilizar un solo clúster no permite realizar una clasificación útil, ya que todas las canciones quedarían dentro del mismo grupo. Por esta razón, este método se tomó solo como apoyo y se comparó con los resultados del método del codo y del método Silhouette.

Selección del número de clústeres

Después de comparar los métodos WSS, Silhouette y Gap Statistic, se decidió trabajar con 3 clústeres. Aunque los métodos no dieron exactamente el mismo resultado, se eligió esta cantidad porque permite dividir las canciones en tres grupos principales y facilita la interpretación de los resultados.

El método del codo mostró una disminución progresiva del error conforme aumentaba el número de clústeres, aunque no presentó un punto de inflexión completamente claro. El método Silhouette presentó valores altos en una cantidad baja de grupos, mientras que Gap Statistic no ofreció una separación clara para más de un clúster. Por esta razón, siguiendo la lógica vista en clase, se decidió trabajar con 3 clústeres.


Resultado con K-means

Primero se aplicó el algoritmo K-means con 3 clústeres. Este método agrupa los datos utilizando centroides, los cuales representan el punto promedio de cada grupo.

En la gráfica se observa la separación de las canciones en tres grupos. Aunque la visualización se muestra en dos dimensiones principales, el análisis se realizó utilizando todas las variables numéricas seleccionadas. Con K-means, las canciones fueron clasificadas de acuerdo con la similitud de sus características musicales.

Figura 7. Resultado del agrupamiento utilizando K-means con 3 clústeres.

En la




gráfica de K-means se observan tres grupos diferenciados. El clúster 1 aparece separado hacia la parte izquierda, el clúster 2 se concentra principalmente hacia la parte derecha y el clúster 3 se ubica en la parte inferior. Esto indica que el algoritmo encontró diferencias entre las canciones de acuerdo con las variables musicales utilizadas.

Resultado con PAM

Después se aplicó el algoritmo PAM con 3 clústeres. A diferencia de K-means, este método utiliza medoides, es decir, registros reales del dataset como representantes de cada grupo.

En la gráfica se observa una nueva distribución de las canciones en tres grupos. PAM permite comparar el agrupamiento obtenido utilizando puntos reales como centros, lo cual puede ser más resistente ante posibles valores atípicos.

Figura 8. Resultado del agrupamiento utilizando PAM con 3 clústeres.



En la gráfica de PAM se observa que las canciones fueron agrupadas en tres clústeres. La distribución de los grupos presenta algunas diferencias respecto a K-means, lo cual indica que el método PAM organiza los datos de una forma distinta al utilizar medoides. Aun así, el resultado sigue mostrando una separación de canciones con características musicales similares.

Resultado con CLARA

Finalmente, se aplicó el algoritmo CLARA con 3 clústeres. CLARA es una variante de PAM diseñada para trabajar con conjuntos de datos más grandes mediante muestreo.

Aunque en esta práctica se trabajó con una muestra reducida de 50 canciones, se aplicó CLARA para seguir el procedimiento visto en clase y comparar sus resultados con K-means y PAM.





Figura 9. Resultado del agrupamiento utilizando CLARA con 3 clústeres.

En la gráfica de CLARA se observa que las canciones fueron agrupadas en tres clústeres. La distribución obtenida es similar a la observada con los otros métodos, lo cual indica que existe cierta consistencia en la clasificación de las canciones según sus características musicales. Aunque CLARA está diseñado para conjuntos de datos grandes, en esta práctica se utilizó con fines comparativos respecto a K-means y PAM.

Archivo final con clústeres

Después de aplicar los tres algoritmos, se agregaron al dataset tres nuevas columnas: `cluster_kmeans`, `cluster_pam` y `cluster_clara`.

Estas columnas indican a qué grupo pertenece cada canción según cada algoritmo. Finalmente, el archivo clasificado fue guardado como `spotify_latinos_clustering.csv`.



speechiness	acousticness	instrumentalness	liveness	valence	tempo	cluster_kmeans	cluster_pam	cluster_clara
0.0769	0.0702	1.95e-04	0.0542	0.773	146.953	2	1	1
0.0473	0.3420	3.57e-05	0.0994	0.255	102.031	2	1	1
0.0556	0.4420	3.04e-06	0.1370	0.883	168.162	1	1	1
0.0450	0.3330	0.00e+00	0.2890	0.556	125.997	2	1	1
0.0379	0.1970	0.00e+00	0.0793	0.964	129.898	2	1	1
0.1420	0.3460	1.20e-02	0.1180	0.802	120.012	2	2	2
0.0488	0.3940	4.87e-04	0.1420	0.613	147.030	2	1	1
0.1460	0.3770	2.79e-03	0.4120	0.580	134.012	2	2	2
0.0325	0.8810	8.49e-05	0.1920	0.362	171.380	1	3	3
0.0411	0.2020	0.00e+00	0.0590	0.817	132.932	2	1	1

```

R 4.5.2 · ~/Temas 3 LAB/1952660_Violeta_N1-N2_Tarea05/Practica5_Parte2_Spotify/
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33
[31] 34 35 36 37 38 40 41 42 43 44 45 46 47 48 49 50

Available components:
[1] "sample"      "medoids"      "i.med"        "clustering"   "objective"    "clusinfo"     "diss"
[8] "call"        "silinfo"      "data"

> datos$cluster_kmeans <- km$cluster
> datos$cluster_pam <- pam_res$clustering
> datos$cluster_clara <- clara_res$clustering
> View(datos)

```

Figura 10. Conjunto de datos final con las columnas de clúster generadas por K-means, PAM y CLARA.

Conclusión:

A lo largo de esta práctica pudimos comprender de manera mucho más profunda el funcionamiento de los algoritmos de agrupamiento, particularmente K-Means y la transición hacia K-Medoides. Consideramos que fue una de las prácticas más extensas y laboriosas del semestre, ya que requirió varios días de trabajo y una interacción constante con cada dato, fórmula y referencia dentro de la hoja de cálculo. Sin embargo, precisamente debido a ese nivel de detalle, también fue una de las prácticas que más aportó a nuestra comprensión teórica del tema.

Aunque estos algoritmos ya habían sido vistos anteriormente en materias relacionadas (Sistemas adaptativos), en ocasiones previas normalmente se trabajaban mediante implementaciones ya automatizadas en lenguajes como Python, donde gran parte del procesamiento ocurre internamente. En esta práctica, en cambio, tuvimos que construir manualmente cada paso del procedimiento: normalización de datos, cálculo de distancias euclidianas, asignación de clústeres, recálculo de centroides e identificación de medoides. Esto permitió comprender de manera más cercana cómo funciona realmente el algoritmo y cómo cada operación afecta la formación de los grupos.

También resultó importante observar la necesidad de normalizar los datos antes de aplicar medidas de distancia, ya que las diferencias de escala entre columnas pueden alterar significativamente los resultados. Del mismo modo, el proceso iterativo de recalcular centroides ayudó a entender cómo los clústeres tienden gradualmente hacia configuraciones más estables.

Aun así, quedaron algunos aspectos que consideramos interesantes para profundizar posteriormente, especialmente la implementación formal de K-Medoides en relación con los centroides y el criterio utilizado para incluir el centroide anterior como parte del cálculo en ciertas iteraciones. Aunque funcionalmente pudimos seguir el procedimiento, consideramos que esos puntos podrían explorarse con mayor profundidad teórica... Quizá debió ocurrir en la clase teórica, no aquí en el laboratorio.

Finalmente, la segunda parte de la práctica realizada en R también resultó útil, ya que permitió visualizar gráficamente los agrupamientos obtenidos. Aunque el trabajo en R automatizaba gran parte del proceso, las representaciones visuales facilitaron la interpretación de los resultados y ayudaron a contrastar el comportamiento de los grupos obtenidos manualmente en Excel.

Referencias:

1. Aggarwal, C. C. (2015). *Data mining: The textbook*. Springer.
2. Bramer, M. (2020). *Principles of data mining* (4th ed.). Springer.
3. Rehman, N. (2024). *Spotify songs and artists dataset | Audio features* [Data set]. Kaggle. <https://www.kaggle.com/datasets/glowstudygram/spotify-songs-and-artists-dataset>